


Data Engineering & Analytics

Basel Husam



iTeam Academic Group

إنّ iTeam فريق أكاديمي تطوعي. وُلِدَ من بذرة الخير التي غُرست في كل نفس فينا لتنتج قوة طلابية قادرة على التغيير أو زرع بصمة لا تُمحى، تحقيقاً لذلك ولأننا نؤمن بأهمية العمل الطلابي وتأثيره في العملية التعليمية والاجتماعية والثقافية وحتى الحقوقية في جامعتنا وكليتنا كلية الملك عبد الله الثاني لتكنولوجيا المعلومات، فإننا نقدم لكم فريقنا العائلة لنصنع بكم ومعكم نجاحات لا تنسى ونسطر لكم أجمل الذكريات ونقدم ما استطاعت سواعدنا أن تُعطي؛ لنرسم لكم بداية درب تكللونه أنتم بالإبداع والحياة.

مجموعتنا الأكاديمية التي تضم العدد الأكبر من طلاب الكلية



Social Media Accounts



iTeam Ju



iTeamJu



iTeam Academy

iTeam Bot

صديقنا البوت يقدم لكم شروحات للمواد وتست بانك ودوسيات وإيميلات الدكاترة، وغيره الكثير من الأشياء يلي ممكن تحتاجوها... أيضاً هو معكم وقت الملل لأنه يقدم لكم روايات وكتب وغيره، وحتى تعرفوا أكثر تفضلوا زوروا صديقنا البوت ولفو لفة فيه!



Table of Contents

Chapter 1 - What is Data Engineering?	2
Data Workflow (The lifecycle for the data):	2
The Five Vs:	6
Chapter 2 – Data Structures	8
Data Structures:	8
SQL:	18
Database schema	21
Data warehouses and data lakes:	24
Chapter 3 - Processing data	29
The difference between Batch and Stream processing:	32
Scheduling:	33
Parallel Computing:	35
Cloud Computing:	37
Read CSV file:	45
Read JSON:	47
Importing CSV:	54
Importing Excel:	57
Importing SQL:	62
Handling Missing Values:	64
Data Cleansing:	66
Orphans Columns:	66
Corrupted Records:	67
Binning Data:	67
Combining, Merge, and Join Data:	68
Data Visualization:	69
Detect Outliers Through Visualization:	69
Feature Engineering:	69
Machine Learning with Iris Dataset:	77
Sentiment Analysis:	77

Chapter 1 - What is Data Engineering?


Chapter 1 topics:

1. Data Engineering and Big Data.
2. Data Engineers vs. Data Scientists.
3. Data pipelines.

❖ *Data Engineering and Big Data:*

Data Workflow (The lifecycle for the data):

1. Data Collection & Storage
2. Data Preparation
3. Exploration & Visualization
4. Experimentation & Prediction



1. Data Collection & Storage:

- Before Everything, we must collect data.
- Collecting data can be from multiple resources, such as data warehouses, database, data lake, etc.

■ لازم اول اشي نعمله انه نجيب انه نجمع البيانات، وعملية التجميع ممكن تكون من اكثر من مكان يعني ممكن تكون من database عادية او data warehouse ... الخ.

2. Data Preparation:

- It's the process of cleaning the data and making it ready for analysis.
- Some of the data preparation tasks:
 - Data discovery
 - Data cleaning:
 - missing values removal
 - handling duplicates
 - delete, fix, or handle corrupted data ... etc.
 - Data transformation
 - Data validation and publishing

3. Exploration & Visualization:

- When the data are well organized and cleaned, then you explore the data and try to understand it, whether by using descriptive statistics or making statistical graphs or finding correlations, or finding differences between two datasets.

4. Experimentation & Prediction:

- The final step is building a model for making predictions.
 - Building a machine learning model allows you to make predictions for the future, or to have answers for specific assumptions.
-

➤ Data Engineers Deliver:

1. The Correct data: high-quality data.
2. In the right form: well-formatted.
3. To the right people: such as:
 - a. Data Analyst
 - b. Data Scientist
 - c. Machine Learning Engineer
4. As efficiently as possible: for example, if the data has length and width, I can calculate the size and give it to the right people instead of the length and width.

➤ A Data Engineers Responsibilities:


1. Ingest data from different resources:
 - تجميع البيانات من مصادر مختلفة.
2. Optimize databases for analysis:
 - الفكرة هون انه من ال database الاصلية او data lake الاصلية اقدر اطلع databases تانيين بساعدوني اني احل مشكلة معينة، مثلا من data lake فيها بيانات عن كثير اشياء، بقدر اني استخلص منها بيانات من نفس المجال وبصبروا بنفس ال domain وبحطهم مثلا ب database لحالهم عشان اشتغل عليهم لحال.
3. Remove corrupted data:
 - بعض البيانات ممكن تكون مضروبة، على سبيل المثال صور ما بتفتح او text فيها رموز غريبة او مش مدعومة. هاي البيانات لازم اتخلص منها.
4. Develop, construct, test, and maintain data architectures.

➤ Data Engineers and Big Data:

- Data Engineers becomes needed more and more because of Big Data.
- Big Data:
 - is very large in volume, so you have to know how to deal with its size.
 - The traditional methods won't work anymore because of its size.

➤ Big Data Growth: امثلة ل اهم اسباب نمو البيانات الكبيرة

- Sensors and devices
- Social media
- Enterprise data
- VoIP (voice communication, multimedia sessions)



- الصورة اللي فوق بتوضحلنا قديش انه البيانات عم بزيد حجمها بشكل هائل وكثير كبير خلال السنين و انه ب 2025 حيوصل حجم البيانات تقريبا 175 Zettabyte

1 Zettabyte = 10^9 Terabyte ■

The Five Vs:

- ال five Vs عبارة عن 5 خصائص لل big data و اسمهم ال five Vs لانه ال 5 خصائص بتبدأ بحرف ال V.

1. Volume (how much?)

- حجم البيانات الكبيرة بكون كبير كثير, بعصرنا الحالي ممكن يكون حجمها بال Petabyte وال Zettabyte, ليهك اول خاصية للبيانات الكبيرة انه حجمها كبير.
- ملاحظة: ممكن بيانات معينة تكون ال big data بس لغيرك لا ... كيف يعني هاد الاشئ؟ على سبيل المثال في بيانات مساحتها 10 Terabytes, انت ك طالب وجهازك الحاسوب ك جهاز طالب حيكون عليك شبه مستحيل انه تقدر تتعامل مع هاي البيانات او تشتغل عليها او حتى تقدر تفتحها او تشوفها, لانه حجمها عملاق بالنسبة لك, بس مثلا لو شركة جوجل اخدت هاي البيانات نفسها عشان تشتغل عليها, حيكون سهل عليها انها تتعامل معها لانه بالنسبة الهاك شركة كبيرة ال 10 تيرابايت ولا اشئ. ليهك نفس البيانات ممكن يختلف تصنيفها من شخص ل اخر, ومجرد ما صار صعب جدا التعامل مع البيانات ممكن نحكي انها big data.

2. Variety (what kind?)

- الاختلاف ب انواع البيانات, ممكن تكون البيانات عبارة عن text او images او tweets او videos او audio او soundtracks ... الخ.
- حتى بنوع البيانات الواحد في اختلاف, يعني مثلا ال images هي عبارة عن صور, بس هاي الصور ممكن تكون صور عن مستشفى, طرق وشوارع, صور من اقمار صناعية (صور للفضاء) وهكذا, ف انه حتى النوع الواحد من البيانات في انواع واشكال مختلفة.

3. Velocity (how frequent?)

- قديه البيانات متكررة, و velocity معناها السرعة, يعني قديش سرعة هاي البيانات او كل قديش بتتغير البيانات, مثال عليها سعر الاسهم بالشركات, ممكن السعر كل ثواني يتغير, ليهك سرعة البيانات كبيرة, و هاد بخلي ال analysis تكون more challenging لانه العملية بتصير اصعب

4. Veracity (how accurate?)

- قديده accurate او دقيقة هاي البيانات؟ وهل المصدر اللي اخدنا منه هاي البيانات موثوق؟
- الهدف مش بس اني اجيب اي بيانات المهم بيانات..... لأ، اذا البيانات اللي انا ماخدها مش صحيحة ف فش فائدة من هاي البيانات
- على سبيل المثال انت بدك تبني model يتنبأ ب مرض معين، بتحتاج تعرف درجة الحرارة، العمر، الجنس، الوزن، والخ من هاي المعلومات. هلا اذا اصلا البيانات اللي اجتني غلط، يعني مثلاً الممرض كان يعيبي البيانات من عنده وبحط اي اشي، ف هاي البيانات عالفاضي، التنبؤ تاع الموديل حيكون غلط لانه اصلا البيانات مش صحيحة.

5. Value (how useful?)

- هل البيانات اللي عندي مفيدة؟ هل حقدر اطلع منها value واصنع منها action واشي ملموس؟ هل لما ابني موديل من هاي البيانات حيفيدني؟ لازم نجابو على هاي الاسئلة قبل منبلش نشتغل على البيانات.
- الهدف اصلا من كل هاد الموضوع وال main goal انه نطلع value ونستفيد من هاي البيانات، ف لو ما بنستفيد منها ف هاي البيانات بتلزمناش.
- مثال على انه نطلع action من البيانات و اشي ملموس، مثلاً انت بنيت موديل يتنبأ ب مرض معين، هاد الموديل مفيد وملموس وممكن المستشفيات تصير تستعمله
كمان امثلة: موديل يتنبأ ب سعر بيت، موديل يستخلص كلام من صورة ... الخ.

Chapter 2 – Data Structures

Data Structures:

➤ Structured Data:

- Easy to read and organize
- Consistent model, rows and columns
- Defined types
- Can be grouped to form relations
- Stored in relational databases
- About 20% of the data is structured
- Created and queried using SQL

- البيانات بكون سهل علي اني اقرأها ويتكون مرتبة
- يتكون البيانات منسقة على شكل سطور واعمد
- نوع البيانات مكون معروف، يعني بسهولة بنقدر نوع البيانات بكل عمود ان كان numerical او categorical
- ممكن نجمع اكثر من بيانات مع بعض ونحطهم بجدول واحد (زي ما حنشوف مثال بالصور تحت)
- يتم تخزينها ب relational databases او RDMS (Relational Database Management System)
- 20% من البيانات الموجودة بالعالم عبارة عن structured data ، ف بنعرف انه نسبة ال unstructured data اكبر بكتير
- يتم انشاؤها والتعامل معها عن طريق query ب SQL، ولهيك بكون استخلاص المعلومات من البيانات بسهولة، يعني ممكن انت تلاقي معلومة بتدور عليها عن طريق كتابة query وحدة ب SQL

Example of Structured Data:***Table 1:*****Employee table**

Index	last_name	first_name	role	team	full_time	office
0	Thien	Vivian	Data Engineer	Data Science	1	Belgium
1	Huong	Julian	Data Scientist	Data Science	1	Belgium
2	Duplantier	Norbert	Software Developer	Infrastructure	1	United Kingdom
3	McColgan	Jeff	Business Developer	Sales	1	United States
4	Sanchez	Rick	Support Agent	Customer Service	0	United States

Table 2:**Relational database**

office	address	number	city	zipcode
Belgium	Martelarenlaan	38	Leuven	3010
UK	Old Street	207	London	EC1V 9NR
USA	5th Ave	350	New York	10118

Merging the two tables:**Relational database**

Index	last_name	first_name	office	address	number	city	zipcode
0	Thien	Vivian	Belgium	Martelarenlaan	38	Leuven	3010
1	Huong	Julian	Belgium	Martelarenlaan	38	Leuven	3010
2	Duplantier	Norbert	UK	Old Street	207	London	EC1V 9NR
3	McColgan	Jeff	USA	5th Ave	350	New York	10118
4	Sanchez	Rick	USA	5th Ave	350	New York	10118

➤ Semi-structured Data:

- Relatively easy to search and organize
- Consistent model, less-rigid implementation: different observations have different size
- Different types
- Can be grouped, but needs more work
- NoSQL databases: JSON, XML, YAML

■ ال semi-structured data هي عبارة عن مكدس ما بين ال structured وال unstructured data ومن الامثلة عليه ال JSON files ، هاد النوع بتكون البيانات مرتبة بطريقة معينة بس مش structured

■ بنقدر نحول ال JSON files على سبيل المثال ل structured data وتكون organized ونحطها ب relational database عن طريق tools وادوات معينة، لهيك هي can be grouped, but needs more work

Example of JSON file:

Favorite artists JSON file

```
{
  "user_1645156": {
    "last_name": "Lacroix",
    "first_name": "Hadrien",
    "favorite_artists": ["Fools in Deed", "Gojira", "Pain", "Nanowar of Steel"]},
  "user_5913764": {
    "last_name": "Billen",
    "first_name": "Sara",
    "favorite_artists": ["Tamino", "Taylor Swift"]},
  "user_8436791": {
    "last_name": "Sulmont",
    "first_name": "Lis",
    "favorite_artists": ["Arctic Monkeys", "Rihanna", "Nina Simone"]},
  ...
}
```

■ في كثير ناس او شركات بتحب تتعامل مع ال JSON/XML files لعدة اسباب، منها انه التعامل مع هاد النوع يكون flexible من ناحية ال transforming، انه ممكن تنقل البيانات كاملة بسهولة عن طريق فلاشة او ايميل ... الخ.

Metadata: Data that provide information about other data.

- يعني على سبيل المثال الفيديو الموجود على يوتيوب يكون الـ description ف كلام اللي يكون بال description box هو عبارة عن الـ metadata والفيديو نفسه هو عبارة عن الـ data ليهيك الـ metadata is data about data.

➤ Unstructured Data:

- Does not follow a model, can't be contained in rows and columns
- Difficult to search and organize
- Usually text, sound, pictures, and videos
- Usually stored in data lakes, can appear in data warehouses or databases
- Most of the data is unstructured
- Can be extremely valuable

- الـ unstructured data ما بتكون مرتبة على شكل rows and columns لانها اصلا ممكن تكون البيانات عبارة عن text او images او videos او audio files ليهيك صعب انه احنا نخليها organized

- البحث فيها صعب، ليش؟ مثلا هلا انت لما تبحث باليوتيوب عن اشي معين، هو بدورك على الاشياء اللي انت بتدور عليه بال titles وال descriptions للفيديوهات، ليهيك اذا انت كنت بتبحث عن اشي معين جوا الفيديو نفسه ف ما رح يطلعك اياه، لانه هاي العملية very complex and difficult كمان مثال ممكن نوخده ع نفس النقطة اللي هي الافلام، انت اذا بتدور ع مشهد معين جوا فيلم وكتبت عنه ب محرك البحث ما رح يطلعك اياه، لانه زي ما حكينا هاد الاشياء لسا عم يشتغلوا عليه و very difficult to implement.

- بنخزنها غالبا بال data lakes، الـ data lake عبارة عن مستودع تخزين واسع، ومن اسمها بحيرة البيانات يعني عبارة عن بحيرة بصب فيها اكثر من اشي، ليهيك ممكن نحكي انه الـ data lake مستودع تخزين بنخزن البيانات فيه وهاي البيانات بتكون من resources مختلفة.

- الـ unstructured data الها قيمة كبيرة وال value تاعتها كثير عالية، بس عملية الـ process فيها اصعب من الـ structured data ، بس بالآخر احنا بهمنا انه نشغل كل الشغل من الـ data collection ل building a model انه يكون في فائدة من هاد الموديل او هاي البيانات، مش كلشي يكون عافاضي

- من ال concepts اللي احنا بنستخدمهم لتتعامل مع ال unstructured data همة ال NLP وال image processing
- ال NLP او ال Natural Language Processing هو كيف نخلي ال computers تقدر تفهم ال voices او ال audio files زي كأنها مكتوبة ومقروءة
- ال image processing هي العملية انه نخلي ال computers تتعرف ع اشياء موجودة بالصورة على شبييل المثال اخليه يعرف الفرق بين البسة والكلب بحيث انه اعطيه صورة واخليه يتنبأ اذا الحيوان اللي بالصورة هو بسة ولا كلب، وهاد الاشئ اسمه image processing بحيث اخلي ال computer يدخل جوا الصورة ويفهمها زي كأنه انسان

Adding some Structure:

- Use AI to search and organize unstructured data
- Add information to make it semi-structured
- زي ما حكينا فوق ممكن نعمل سيرش فيهم عن طريق ال NLP وال image processing وهذول الحالتين او التقنيتين همة عبارة عن AI
- برضه زي ما حكينا فوق مثلاً الفيديوهات اذا ضفتلها description ممكن تصير semi-structured لاني انا هون بسهل عملية البحث بين هاي ال unstructured data

DATA LOCALITY: is the process of moving computation to the node where that data resides, instead of vice versa.

- يعني على سبيل المثال في بيانات مساحتها 10 Terabyte ف انت حيكون صعب عليك انك تقدر تتعامل معها من خلال جهازك البسيط، لهيك مبدأ ال data locality بحكيك انه بدل ما انت تجيب الداتا عندك وتشغل عليها وتكتب كود عليها ... خلي الكود تاعك يروح محل ما الداتا مخزنة (مش بجهازك) ويتطبق الكود عليها وهي هناك، وانت بتقدر تشوف ال results وتاخذها.

Summary:

- Structured data
- Semi-structured data
- Unstructured data
- Difference between the three
- Give examples

Questions:

Q1: Order the following:

- Exploration and visualization
- Data preparation
- Data collection and storage
- Experimentation and prediction

Q2: DE or not DE (Data Engineering or not):

- A. Optimizing the customers for analysis
- B. Ensuring corrupted, unreadable music tracks are removed and don't end up facing customers
- C. Gathering music consumptions data from desktop and mobile sources
- D. Running an experiment to identify the optimal search bar positioning in the app
- E. Based on their listening behavior, predict which songs customers are likely to enjoy
- F. Building a visualization to understand listening patterns by city

Q3: True or False:

- A. Value refers to how actionable the data is
- B. Data types refer to the variety of the data
- C. Velocity refers to how big the data is
- D. Volume has to do with how trustworthy the data is
- E. Veracity refers to how frequently the data is generated

Q4. Tell me the truth:

In 2012, IBM declared that 90% of the data in the world had been created in the past 2 years. That same year, the amount of digital data in the world first exceeded 1 zettabyte (1 billion terabytes). In 2020, we're expected to reach 44 zettabytes. This big data era led to the advent of two new roles: data engineers and data scientists, you just studied the differences between these two roles.

Let's have a quick sanity check: which of the following options is true?

- A. Data engineers intervene at the very end of the data workflow
- B. Data scientists build pipelines
- C. Data engineers need strong statistical expertise
- D. Data engineers enable data scientist

Q5: Assign the task to the data engineer or the data scientist:

- A. Provide listening sessions data so it can be analyzed with minimal preparation work
- B. Find out in which countries certain artists are popular to give them insights on where to tour
- C. Ensure that people who use the databases can't erase music videos by mistake
- D. Use Python to run an analysis on whether users prefer having the search bar on the top left or the top right of the Spotify desktop app
- E. Use Java to build a pipeline collecting album covers and storing them
- F. Identify which customers are likely to end their Spotify subscriptions, so marketing can target them and encourage them to renew

Q6: It's not true:

The main objective, when setting up data pipelines, is to improve the efficiency with which data flows from its ingestion to the final user

Most of the options below are true, but one is false, which one is it?

- A. Data pipelines ensure an efficient flow of the data through the organization
- B. Data pipelines automate data extraction
- C. Data pipelines necessarily include a transformation step
- D. ETL stands for Extract, Transform, and Load

Answers:

Q1:

- A. Data collection and storage
- B. Data preparation
- C. Exploration and visualization
- D. Experimentation and prediction

Q2:

Data Engineering tasks:

- Optimizing the customer's databases for analysis (A)
- Ensuring corrupted, unreadable music tracks are removed and don't end up facing customers. (B)
- Gathering music consumption data from desktop and mobile sources (C)

All the others are *not data engineering tasks*

Q3:

- $A + B \rightarrow \text{True}$
- $C + D + E \rightarrow \text{False}$

Q4: Data Engineers enable Data Scientist**Q5:**

- $A + C + E \rightarrow DE$ (Data Engineering)
- $B + D + F \rightarrow DS$ (Data Scientist)

Q6: Data pipelines necessarily include a transformation step

- See all the questions by taking this course “Data Engineering for Everyone” by datacamp from the [link here](#)

SQL:

- Structured Query Language
- Industry-standard for Relational Database Management System (RDBMS)
- Allows you to access many records at once, and group, filter or aggregate them
- Close to written English, easy to write and understand
- Data engineers use SQL to **create and maintain databases**
- Data scientists use SQL to **query (request information from) databases**

■ ال SQL يعتبر ال standard للتعامل مع ال RDBMS، ف ال SQL هو الشكل العام للغة بس اللي احنا بنستخدمها بتكون تفرعات من SQL نفسه، يعني احنا لما نكتب كود SQL هو اوك يكون SQL بس الكود يكون عبارة عن MySQL او PostgreSQL ... الخ
لهيك ال SQL هو الشكل العام لهاي اللغة بس الكود اللي احنا بنكتبه يكون عبارة عن واحد من ال implementations لها

■ بتخليك تقدر توصل لعدد من ال records او ممكن نسميهم ال rows بسهولة، او انك تجمع مجموعة من البيانات مع بعض، او تفلترهم بسهولة

■ قريبة من اللغة الانجليزية، يعني ممكن واحد ما بفهم بالبرمجة اشي ويقرأ ال SQL statement ويعرف شو بتعمل لانه ال statements نفسهم واصفين حالهم

■ الفرق بين استخدام مهندس البيانات لل SQL عن عالم البيانات هو انه مهندس البيانات يستخدم ال SQL ليصنع ال databases ويحافظ عليهم ويكونوا efficient as possible.
اما عالم البيانات يستخدم ال SQL ليستخلص بيانات من ال databases اللي عملها مهندس البيانات

Remember the employees table

index	last_name	first_name	role	team	full_time	office
0	Thien	Vivian	Data Engineer	Data Science	1	Belgium
1	Huong	Julian	Data Scientist	Data Science	1	Belgium
2	Duplantier	Norbert	Software Developer	Infrastructure	1	United Kingdom
3	McColgan	Jeff	Business Developer	Sales	1	United States
4	Sanchez	Rick	Support Agent	Customer Service	0	United States

➤ SQL for data engineers

- Data engineers use SQL to create, maintain and update tables.
- Now let's create the Employee table using SQL:

```
CREATE TABLE employees (
  employee_id INT,
  first_name VARCHAR(255),
  last_name VARCHAR(255),
  role VARCHAR(255),
  team VARCHAR(255),
  full_time BOOLEAN,
  office VARCHAR(255)
);
```

- طيب خلينا نشرح ال statements اللي فوق:
- يستخدم CREATE TABLE لحتى انشي table بعدين بكتب اسم ال table اللي انا بدي اياه وبهاي الحالة اسم ال table حيكون employees
- بعدين ال 7 اسطر اللي بعدهم مقسومين لنصين، النص اللي عالشمال بكون اسم ال column اللي انا بدي اياه، وممنوع ب اسم ال columns يكون في spaces او فراغات او special characters او اشي من هاي الاشياء، اذا بدك تكتب كلمتين بتوصلهم عن طريق ال _ underscore
- اما النص اللي عاليمين هو نوع ال data type لهاد ال column مثلا بدي ال data type يكون integer ف بكتب INT او بدي اياه string ف بكتب VARCHAR() وبحط جوا القوس تاعها ال maximum NO. letters او بدي اياه Boolean ف بكتب BOOLEAN
- ممكن انت تسأل ليش قاعد بكتب هاي الشغلات بالكود ب upper case، ال SQL مش case sensitive ليهك ان كتبتها Boolean او BOOLEAN مش حيفرق، بس الطريقة المتعارف عليها انه ال reserved words بال SQL اكتبهم ب upper case عشان اميزهم عن اسماء columns وهاي الاشياء
- ممكن حدا يسأل ليش ال Boolean ما خليته integer، هو بزبط هاد الحكي سينس انه القيمة رح تكون اما 1 او 0، ليهك ان حطيت int او Boolean مش حيفرق، بس ال Boolean بخزن بالذاكرة اقل، ليهك انت لما يكون عندك بيانات جدا ضخمة، بكون اشي مهم انه انت تقدر تخفف من مساحة ال database قد ما بتقدر

➤ SQL for data scientists


- Data scientists use SQL to query, filter, group, and aggregate data in tables.
- Now let's see an example of how to write a query to select the first and last name of the employees who have the word "Data" in their role:

```
SELECT first_name, last_name  
FROM employees  
WHERE role LIKE '%Data%'
```

- هون انا بدي اختار 2 columns اللي همة ال first name وال last name لهيك رح استخدم ال SELECT ستيتمينت، اللي هي رح تعطيني هдол ال columns
- طيب ال SQL ما بعرف هдол ال columns من وين يجيبهم، لهيك انت لازم تحكيه من اي table لازم يجيبهم، عن طريق ال FROM وبكتب بعدها اسم ال table
- اذا انا كان عندي شرط معين او بدي اطول فئة معينة او اشي بستخدم ال WHERE وبكتب بعدها اسم ال column اللي بدي اطبق عليه الشرط وهون انا مثلا بدي اطول الناس اللي ال role تاعهم مكتوب في كلمة Data، مش مهم اذا في بعدها او قبلها اشي لهيك انا رح اسخدم ال (%) percentile واذا حظيتها قبل الكلمة معناها انه مش مهم شو يكون قبلها، واذا حظيتها اخر الكلمة معناها مش مهم شو يكون بعدها وهكذا وبستخدم ال LIKE قبلها عشان تزبط عندي ال query

Database schema

- Databases are made of tables
- The database schema governs how tables are related
- Schema means tables are related to each other



- ال ARTISTS, ALBUMS, SONGS, PLAYLISTS عبارة عن tables
- الخطوط التي بين ال tables هي الطريقة التي يربط ال tables بين بعض ف هي عبارة عن ال relationship between tables
- ال artist_id بال ARTISTS table عبارة عن ال primary key (مفتاح أساسي) وال artist_id بال ALBUMS table عبارة عن ال foreign key (مفتاح ثانوي)
- كل table لازم يكون فيها primary key بس مش لازم يكون فيها foreign key

➤ Several implementations (only for read):

▪ SQLite:

○ Advantages:

- It is a library, and the size of the library can easily be under 600 KB
- It acts as a complementary solution for enterprise RDMBS
- Open-source

○ Disadvantages:

- Lack of multi-user capabilities
- Can't deal with large datasets like Big Data

▪ MySQL:

○ Advantages:

- Support multi-user features
- Simple to install and use
- The ease of use and manageability makes it a great tool for websites
- One of the most popular open-source and large-scale RDBMS

○ Disadvantages:

- Lack of full-text search and slow concurrent read-writes
- Not work well with long-running SELECTs and is best suited to smaller SELECTs

▪ PostgreSQL:

○ Advantages:

- Open-source
- On top (compared to MySQL) when running long SELECTs
- The extensibility of the PostgreSQL database also makes it a perfect candidate for research and scientific projects.

○ Disadvantages:

- can be seen during frequent UPDATES, where due to no support for clustered indexes
- PostgreSQL can have a huge adverse impact on performance compared to MySQL databases.

▪ Oracle SQL:

○ Features of Oracle:

- Ease of data recovery when compare to databases
- The RDMS system can easily handle large amounts of data
- Allows you to change platforms at any time
- It can be used for read-write, reporting, testing, or backups, reducing the load on the primary database
- Support for hardware and OS-specific virtualization technologies

▪ SQL Server:

○ Features of Microsoft SQL Server:

- Support tools SQL Server profiler, BI tools, SQL Server Management Studio, and Database Tuning advisor
- Offers online support and documentation
- Display errors
- An activity monitor feature with filtering and automatic refresh
- Importing and Exporting from SQL Server Management Studio

For more information about SQLite, MySQL, PostgreSQL click [here](#)

For more information about Oracle SQL, SQL Server click [here](#)

Summary:

- SQL = industry standard
- Explain how Data Engineers and Data Scientists use it differently
- Database schema
- SQL implementations

Data warehouses and data lakes:

➤ Data lake:

- Stores all the raw data
- Can be petabytes (1 million GBs)
- Stores all data structures
- Cost-effective
- Difficult to analyze
- Requires an up-to-date data catalog
- Used by data scientists
- Big data, real-time analytics



■ بنخزن فيها جميع انواع البيانات (structured, unstructured)

■ البيانات بتكون موجودة وجاهزة عندي بال data lake ما بروح اجيبها من مكان لانها اوريدي موجودة عندي
ولما بدى اعدل اشي عاليبيانات بعدلها عال data lake لانها البيانات الاساسية وكلشي بكون موجود فيها، ف لما بدى اعدل اشي بعدل عليها، لانه اذا عدلت ب مكان وما عدلت فيها بصير عندي اشي اسمه inconsistency يعني تناقض، لانه بزبطش اشي يكون قيمته غير بمكان ثاني

■ صعوبة بعملية التحليل، لانه بكون عندي بيانات كثيرة و بجميع الانواع، لهيك صعب تحليلها

■ بحتاج data catalog ورح نشرح عنه اكثر كمان شوي

■ عالم البيانات اللي بتعامل مع ال data lakes

■ بما انه هاد النوع بيحمل جميع انواع البيانات ف رح يتكون عندي big data

❖ Data warehouse:

- Specific data for specific use
- Relatively small
- Stores mainly structured data
- More costly to update
- Optimized for data analysis
- Also used by data analysts and business analysts (BI)
- Ad-hoc, read-only queries



- يتكون بيانات مخصصة لغرض معين، يعني كل البيانات يكون في اشي مشترك بينهم ويكونوا متشابهين
- يتكون اصغر حجم من ال data lake، بس مش المقصود انه حجمها صغير يعني 5 MB او اشي ... لا حجمها صغير مقارنة بال data lake، ويمكن يكون حجمها بالتيرابايت عادي
- بنخزن فيها بس ال structured data واللي يكونوا نفس النوع
- يكون صعب علي اناي اعدل عليها
- مخصصة لتحليل البيانات
- محلل البيانات او اللي يشتغل ب مجال ال (Business Intelligence) BI يتعاملو معها
- Ad-hoc, read-only queries معناها انه هاي البيانات قيمتها محددة وخلص، ف انت لما تحلل البيانات بتحللها عن طريق ال read فقط، يعني انت بتقدر تشوف اللي بدك اياه من البيانات بس ما بتقدر تعدل عليها، لانه زي ما حكينا فوق، اذا بدك تعدل بتعدل ال data lake نفسها
- معلومة مهمة جدا، ال data warehouses دائما بتكون structured data، ممكن واحد يجي يحكي لي كيف بتكون structured وهو ممكن يكون فيها صور، على سبيل المثال صورة الالبوم، باجي بقلك هي ما بتحمل الصورة نفسها، هي بتحمل index للصورة، والصورة نفسها بتكون موجودة بال data lake، وبتكون الصور كلها مرتبة ب طريقة معينة جوا ال data lake وبرضه ب مساعدة ال data catalog بتقدر نحقق هاد الاشئ

➤ Data catalog for data lakes:

- What is the source of this data?
- Where is this data used?
- Who is the owner of the data?
- How often is this data updated?
- Good practice in terms of data governance
- Ensures reproducibility
- No catalog → data swamp

- ممكن نحكي عن ال data catalog زي ال meta data انه هو data about the data
- من وين مصدر هاي البيانات؟ وين بستخدموا هاي البيانات؟ مين مالك هاي البيانات
كل كم يتم تحديث البيانات؟ كل هاي الاسئلة مهمة ولازم تكون اجوبتها موجودة بال data catalog
- لازم اتأكد انه بقدر ارجع انتج او استخدم هاي البيانات، انه مش اذا خربت معي البيانات ما اقدر اجيبها كمان مرة
- اذا ما كان في data catalog رح يتكون عندي data swamp
وال data swamp من اسمه انه مستنقع للبيانات، يعني البيانات بتكون معفشكة ومش منظمة
واشي مش كويس ابدأ انه يكون عندي data swamp، والصورة التحت رح تشرحك الاشياء




- Good practice for any data storage solution:
 - Reliability الموثوقية
 - Autonomy الحكم الذاتي
 - Scalability قابلية التوسع
 - Speed السرعة

➤ Database vs. data warehouse

- Database:
 - General term
 - Loosely defined as organized data stored and accessed on a computer
- Data warehouses are a type of database
- كلمة database لا يعني انه structured data، كلمة database يعني قاعدة البيانات بشكل عام يعني اي اشي بنخزن فيه البيانات بكون عبارة عن database والامثلة اللي اخدناها زي ال data lakes وال data warehouses هتكون عبارة عن انواع من ال databases

Summary:

- Data lakes
- Data warehouses
- Databases
- Data catalog
- Data swamp



- زي ما بنعرف انه احنا ب هاد الكورس رح نشغل و رح نفهم المادة من خلال Spotflix dataset وهلا رح نشرح هاد ال pipeline ونوضح اجزاء
- رقم 1: بوضلي انه في بيانات عم تنلم من اكثر من مصدر وعم تتخزن ب مكان، هاد المكان هو ال data lake، لهيك زي ما حكينا انه ال data lake بكون فيها جميع انواع البيانات ومن مختلف المصادر
- رقم 2: بعد ما انا جمعت كل البيانات ب مكان واحد هلا اجا الدور اني اقسماها وارتبها، و زي ما حكينا قبل انه احنا بندرس ع spotflix dataset، و spotflix عبارة عن تطبيق ل سماع الاغاني، زيه زي spotify, apple music, anghami, sound cloud, ... etc ف هاي البيانات شو ما كانت اكيد بنقسمها ل عدة اشياء زي artist, albums, track, playlist, customer, employee ف اني اقسم البيانات تاوتي لهاي الاصناف وكل صنف اخزن بياناته ب مكان معين، هاد المكان اسمه data warehouse وزي ما حكينا انه ال data warehouse بكون مخصص ل اشئ معين، وهاد اللي احنا عملناه قبل شوي
- رقم 3: على سبيل المثال الاغنية او ال track كان بصيغة flac. وانا بدى احوله ل صيغة ogg. هون ب هاي الحالة انا عملت transformation وخزنت البيانات اللي عدلت عليها ب data warehouse جديدة عشان اقدر اتعامل معها بالطريقة اللي انا بدى اياها، فالفكرة هون انا اذا بدى اعدل على اشئ بخزنه ب data warehouse جديدة وبتعامل معه وهو هناك

Chapter 3 - Processing data

A general definition:

Data processing: converting raw data into meaningful information

Data processing value:

Conceptually	At Spotflix	Explain (شرح)
Remove unwanted data	No long term need for testing feature data	هون الفكرن نحذف البيانات اللي ما بنحتاجها وما بتعطينا فائدة، وكمثال عليها انه نحذف features معينة من data set تاعة spotflix
Optimize memory, process, and network costs	1. Can't afford to store and stream files this big 2. No need for a lossless format	بدي احوال اخفف من ال memory قدر الامكان ليهيك اذا كان في فايلات كبيرة مش راح اقدر اتحمل تكلفة تخزينها واذا كان في عندي بيانات مش مهمة بشيلها برضه عشان اخفف عال memory برضه
Convert data from one type to another	Convert songs from .flac to .ogg	احول البيانات من نوع ل اخر، زي اني اغير ال songs من امتداد .flac ل .ogg
Organize data	Reorganize data from the data lake to data warehouses	بدي ارتب البيانات تكون organized زي كمثال اني اطلع من ال data lake اطلع data warehouses وزلي ما حكينا قبل انه ال data warehouses organized دايما بتكون organized

To fit into a schema/structure	Employee table example	لازم لما ادخل البيانات ادخلها ب ترتيب ال schema تاعة ال database، على سبيل المثال ال employee table ال الترتيب لازم يكون فيها last name بعدين first name بعدين role بعدين team... الخ
Increase productivity	Enable data scientists	بدي ازيد فعالية هاي البيانات واخلوها مفيدة قدر الامكان، ولما اعمل انا هيك ف انا عم بمكن ال data scientist وبساعده ب توفير بيانات مفيدة ومهمة

How Data Engineers process data:

A. Conceptually: Data manipulation, cleaning, and tidying tasks:

1. that can be automated. 2. that will always need to be done

At Spotflix: 1. Rejecting corrupt song files. 2. Deciding what happens with missing metadata

- لازم اتلاعب بالبيانات واعملها cleaning وهاد الاشئ ممكن يصير ب اكثر من طريقة: اشطب وامحي الملفات المضروبة واتخلص منها برضه اقرر شو لازم اعمل بال missing values، هلا اعييهم ولا امحيهم وذا اعييهم اعييهم ب ايش؟ ال mean ولا median ولا mode وكل هاي الاشياء لازم نقرر ها عشان تكون البيانات مفيدة

B. Conceptually: Store data in a sanely structured database

At Spotflix: Separate artists and albums tables...

- لازم اخزن البيانات بشكل سليم على شكل structured databases، على سبيل المثال افصل ال artists وال albums tables

C. Conceptually: always need to be Create views on top of the database tables

At Spotflix: ...but provide view combining them

- بدي اعمل views وال view ب عالم ال databases هو عبارة عن ال table نفسها بس الفرق اني ما بقدر اعدل على البيانات فيها، وغير هيك بقدر كمان اعمل view بتضم مجموعة columns من table ومجموعة columns من table ثانية، وهاد الاشئ كثير يساعد انه نقدر نشوف البيانات بسهولة ومن دون الخوف انه نشطب او نعدل عالبيانات بالغلط

D. Conceptually: Optimizing the performance of the database

At Spotflix: Indexing

- لازم احسن من اداء قاعدة البيانات وهاد الاشئ يتم ب اكثر من طريقة منها ال indexing، ومعنى ال indexing فهو ممكن نحكي انه زي الفهرس انه كيف يكون مقسم بترتيب الاحرف الابجدية انه (أ،ب،ت،..الخ) وهون نفس الاشئ، انه اذا انا بدي ادور على اشئ معين ما ادور عليه بين كل البيانات، لا يكون عامل indexing وبصير يدور عليه بال index اللي هو فيه وهاد الاشئ بسرعه عملية البحث وبحسن اداء ال database

Batch and Stream processing:



The difference between Batch and Stream processing:

▪ Batch processing (دفعات):

- Ad-hoc or Scheduled processing
- Collection of data

- ال batch processing طريقة ال process فيه بتكون على شكل حزم شو يعني حزم اصلا؟ يعني دفعات دفعات، على سبيل المثال انت كل ساعة رح تيجيك مجموعة من البيانات اللي لازم تعملها processing ف هون انا حكيت كل ساعة حيجيك مجموعة، ف البيانات بتيجي على شكل دفعات والعملية بتكون منظمة

- من اشهر الامثلة عليها Apache Spark, Hadoop

▪ Stream processing (مستمر):

- Real-time processing
- Continuous data

- ال Stream processing طريقة ال process فيه بتكون مستمرة ومتواصلة وبتضلها جارية كيف يعني؟ يعني على سبيل المثال انه انا ممكن بعد دقيقة تيجيني شوية بيانات، وبعد كمان دقيقة تيجيني بيانات مضاعفة، ف انا هون بعمل process اول ب اول، يعني كل ما تيجيني بيانات او تيجيني معلومة، ف عالسريع بعملها processing وهاي هي العملية بال stream processing

- ومن اشهر الامثلة عليه Apache Storm, Flink

- Summary:

- What data processing is
- Why it's necessary
- What it consists in
- How we process data at Spotflix

Scheduling:

- Can apply to any task listed in data processing
 - Scheduling is the glue of your system
 - Holds each piece and organize how they work together
 - Runs tasks in a specific order and resolves all dependencies
- بتقدر تعمل اي عملية على البيانات خلال تجهيزها، على سبيل المثال data cleaning, delete corrupted data, etc
- عملية ال scheduling او الجدولة هي عبارة عن الالية او الطريق او ال process كاملة اللي رح يشتغل عليها ال system تبعك
- لما تكون ال data اللي عندي كثير كبيرة ف ما بقدر اني اتعامل معها بسهولة، مثلا اذا بدي اطلع ال mean لعمود معين ما بقدر اطلعه بسهولة، لازم اقسم ال data تاغتي ل اجزاء وبعمل الية معينة بحيث انه اعمل عملية على كل جزء واقدر بالاخر بس اخلص منهم كلهم اوصل للمعلومة اللي بدي اياها
- بنجري العمليات بترتيب معين، يعني مثلا انا ما بقدر اطلع ال mean ل عمود معين وهاد العمود فيه corrupted data او فيه null values لهيك انا لازم اتعامل مع ال corrupted او ال null values اول، بعدين اطلع ال mean ، لهيك بنستنتج انه اشي كثير مهم اني امشي على ترتيب معين، لازم ال system تاغنا يكون مبني على tasks الها order معين وبحل جميع المشاكل
- من اشهر الادوات او ال tools اللي بتعمل scheduling لل data تاغتك، هو Apache Airflow

Manual, time and sensor scheduling:

- Manually
Example: Manually update the employee table
- Automatically run at a specific time
Example: Update the employee table at 6 AM

- Automatically run if a specific condition is met → Sensor scheduling
Example: Update the department tables if a new employee was added

- بشكل يدوي بغير عاليات، او بشكل اوتوماتيكي ب وقت معين، او بشكل اوتوماتيكي لما يتحقق شرط معين

Batches and Streams:

- Batches:
 - Group records at intervals
 - Often Cheaper
- Streams:
 - Send individual records right away

- ال batches يكون اسهل من ال stream لانه بال batches البيانات already بتكون عندك ف انت عارف كيف بدك تتعامل معها، اما ال stream ف الداتا بتكون record by record ف انت ما بتعرف شو طبيعة البيانات اللي رح تيجيك

Scheduling tools



- Summary:
 - What scheduling is
 - Different ways to set it up
 - Difference between batches and streams
 - How Scheduling is implemented at Spotflix
 - Airflow, Luigi

Parallel Computing:

- Basis of modern data processing tools
- Necessary:
 - Mainly because of memory
 - Also for processing power
- How it works:
 - Split tasks up into several smaller subtasks
 - Distribute these subtasks over several computers

- اشي مهم واساسي في ادوات معالجة البيانات، وهي ضرورية لانه بعض العمليات بتحتاج مساحة ذاكرة كبيرة جدا وبرضه بسبب انها قوية وفعالة في عملية معالجة البيانات، وبتتم هاي العملية عن طريق تقسيم المهمة ل اجزاء اصغر وبعدين بنوزعهم ونعملهم distribute على عدة اجهزة

- رح نشرح عن ال parallel computing او الحوسبة المتوازية باختصار، المبدأ تاعها انه اقسم تاسك معين باخذ معي وقت طويل ل اكثر من جزء وكل جزء احطه ب جهاز لحال او system لحال عشان استغل الوقت وانجز ال task بوقت اقل، هالأ مش كل ال tasks بزيبط اني اعملهم parallel computing على سبيل المثال:

انا عندي 10 مليون record وبدي اطلع ال mean تاعهم، هالأ اذا بدي اقسم 10 اجزاء ل 10 اجهزة ف كل جهاز حياخد مليون، واذا بطلع لكل جهاز ال mean ف هون العملية بتصير غلط عندي، يعني اذا كل جهاز طلعت ال mean لل داتا اللي عنده وبعدين اني اطلع ال mean لل means ف هاد اشي غلط رياضيا، لهيك هاد ال task ما بزيبط اعمله parallel بشكل دايركت، بس ممكن يزيبط معي هاد التاسك بطريقة تانية، هي اني لكل جهاز اطلع المجموع او ال sum للبيانات تاعتهم وبعدين بجمع كل ال sums وبعدين باخذ ال mean تاعهم عن طريق اني اقسم المجموع كامل تاع كل الاجهزة على 10 مليون.

- مثال ثاني: انا عندي 10 الاف بحث، بدي اطلع كل كلمة كم من مرة تكررت بكل الابحاث، ف اللي بعمله اني بعطي كل جهاز جزء من الابحاث، وكل جهاز بدي اياه يطلع كل كلمة كم من مرة تكررت، وبعدين بجمع نتائج كل الاجهزة ويعمل aggregation ل الهم، وجمعهم ب dictionary واحد بحمل النتائج كاملة والجواب اللي انا بدي اياه

- مش دائما ال parallel computing يكون الحل لكل اشي، على سبيل المثال، في بعض الاشياء او ال tasks ما بتحتاج parallel ولو عملناها parallel ف بالعكس بتصير توخذ وقت اطول، يعني اذا كان في عندي مشكلة صغيرة او task و هاد التاسك already صغير ف ما بتحتاج اني اعمله parallel computing ولو عملته ف رح يوخد مني وقت اطول لانه لما اقسم المشكلة الصغيرة ل مشاكل اصغر وابعتها ل جهاز، ف هاد الجهاز بده يعرف كيف يتعامل معها وهاي العملية اصلا بتوخد وقت، ف ما في داعي اني احل مشكلة صغيرة بال parallel computing
- وكمان شغلة، انه مش دائما اذا زدت عدد الاجهزة اللي رح اعطيها subtask ف هاد اشي احسن ... لا، مش ضروري، انت لازم توخذ وتستعمل اجهزة على قد حاجتك وعلى قد ما بتحتاج ال problem ل اجهزة، ف لازم يكون عندي balance بهاد الموضوع


Benefits and risks of parallel computing:


- Advantages:
 - Extra processing power
 - Reduced memory footprint
- Disadvantages:
 - Moving data incurs a cost
 - Communication time
- Summary:
 - Benefits and risks
 - How it's implemented at Spotflick

Cloud Computing:

- Servers on premises (الجهاز اللي عندك بالبيت او الشغل):
 - Bought
 - Need space
 - Electrical and maintenance cost
 - Enough power for peak moments
 - Processing power unused at quieter times
- Servers on the cloud (الموجود عالنت):
 - Rented
 - Don't need space
 - Use just the resources we need
 - When we need them
 - The closer to the user the better

Cloud Computing for data storage:





- ب رقم 1 احنا هون اخدنا صور ال albums (مش ال albums نفسهم) وخرنناهم ب AWS S3 اللي هو ال cloud file storage الخاص ب امازون

- ب رقم 2، مش احنا حكينا قبل اذا انا بدي اعمل عملية transformation للبيانات مثلا بدي احول امتداد ال track من flac ل .ogg. هاي العملية بقدر اعملها عال cloud وهون احنا استخدمنا AWS EC2 اللي هو ال Computation الخاص ب امازون

- ب رقم 3 خزننا ال employee table ب AWS RDS اللي هون Database خاص ب امازون

- Multicloud:

○ Pros (ايجابيات):

- Reducing reliance on a single vendor
- Cost-efficiencies
- Local laws requiring certain data to be physically present within the country
- Militating against disasters

○ Cons (سلبيات):

- Cloud providers try to lock in consumers

- Incompatibility
- Security and governance

- Summary:

- Benefits and risks of cloud computing
- How it is implemented at Spotflick
- Can cite the main cloud providers

- كل القبل كان عبارة عن introduction للمادة وعن ال data engineering بشكل عام
وهلا رح نبليش تطبيق عملي عالموضوع ونمشي بال pipeline اللي حكينا عنه كامل

- **What you learned – Chapter 1:**

- What Data Engineering is
- How important it is
- How data engineers differ from data scientists
- What a data pipeline is and how it works

- **What you learned – Chapter 2:**

- The different structured data can take
- How fundamental SQL is
- The difference between data lakes, data warehouses, and databases

- **What you learned – Chapter 3:**

- How data is processed
- How scheduling holds it all together
- Parallel Computing
- Cloud Computing

- **And some more:**

- What SQL code actually looks like
- Main tools and technologies used in data engineering
- And some more


The Practical Part (الجزء العملي):

```

1 from faker import Faker
2 import csv
3
4 output = open("data.csv", "w")    # Make a file called "data"
5                                   # with csv format to write inside it
6
7 fake = Faker() #Make object from Faker library
8
9 header = ['name', 'age', 'street', 'city', 'state', 'zip', 'lng', 'lat']
10
11 mywriter = csv.writer(output) #Object for writing inside the output
12 object (data.scv)
13 mywriter.writerow(header) #Write the first row "COLUMNS NAMES"
14
15 for r in range(1000): # Making 1000 record dataframe
16     mywriter.writerow([fake.name(),
17                         fake.random_int(min=18, max=80, step=1),
18                         fake.street_address(), fake.city(),
19                         fake.state(), fake.zipcode(),
20                         fake.longitude(), fake.latitude()])
21
22 output.close() #Close the file

```

- طيب، خنبش نشرح الكود، ب اول سطرين عملنا import لل packages اللي رح نستخدمهم واللي همة: faker عشان نجيب بيانات وهمية ونتدرب ع انه كيف نتعامل معها، و csv عشان نعمل ملف ب امتداد csv ونخزن فيه هاي البيانات عشان نقدر نتعامل معه
- ال faker library ما بتكون نازلة built in من anaconda ليهيك انت لازم تنزلها، وفي كثير طرق للتنزيل ومنها:



- افتحوا ال anaconda prompt واكتبوا **pip install faker**

```
Anaconda Prompt (anaconda3)
(base) C:\Users\basel>pip install faker
Requirement already satisfied: faker in c:\users\basel\anaconda3\lib\site-packages (13.3.4)
Requirement already satisfied: python-dateutil>=2.4 in c:\users\basel\anaconda3\lib\site-packages (from faker) (2.8.2)
Requirement already satisfied: six>=1.5 in c:\users\basel\anaconda3\lib\site-packages (from python-dateutil>=2.4->faker) (1.16.0)
(base) C:\Users\basel>_
```

بطلعكم انه بلش ينزلها، انا هون طلعتي هيك لاني already منزلها


- نرجع للكود، بسطر 4 علمنا متغير او object عبارة عن file، واحنا اخدنا انه عشان نتعامل مع ال files بنستخدم open statement وبنحط جواها اسم الملف، وطريقة تعاملتي معه هون اسم الملف حيكون data.csv وطريقة تعاملتي معها حيكون write وبحطها بالكود w
- سطر 7 علمنا object من ال library faker اسمه fake
- سطر 9 علمنا list ب اسماء ال columns اللي انا بدني احطهم بال داتا تاعتي
- سطر 11 علمنا متغير او object هاد ال object شغلته انه يكتب عالفائل اللي سميناه data، كيف خليناه يعمل هيك اشي؟ عن طريق استخدمت ال library csv واخذت منها ال method اللي اسمها writer ومن اسمها انه وظيفتها انها تكتب عالملفات، وبحط جوا الاقواس اسم الملف اللي انا بدني اكتب فيه او احط فيه البيانات
- سطر 13 علمنا اول عملية كتابة عن طريق المتغير mywriter واستخدمنا منه ال function اللي اسمه writerow ومن اسمه انه يكتب سطر كامل، واول سطر كتبناه اللي هو اسماء ال columns او المتغير اللي اسمه header او ال list اللي حطينا فيها اسماء الاعمدة، ف هيك احنا كتبنا اول سطر بالملف
- سطر 15 علمنا loop حتلّف 1000 مرة لانه انا بدني اعمل الف record او الف سطر من البيانات
- سطر 16-20 جوا ال for loop علمنا انه يكتب سطر، وهاد السطر حيكون عبارة عن بيانات عشوائية او fake من ال library نفسها، ومشينا بنفس ترتيب ال header، يعني اول اشي بال header كان name ف حطينا اول اشي name وهكذا
- ملاحظة 1: انا ممكن ب اسم ال header اكتب zip بس لما احي بدني استخدم هاي ال library وبدي اياها تعطيني بيانات fake ف لازم اكتب اسم ال function صح، يعني بكتبه fake.zipcode()
- ملاحظة 2: في اكثر من اشي بتقدر تستفيده من ال faker library، يعني فيها اشي غير ال name وال city والخ واذا حابين نتعرفوا عليها اكثر بتقدر تقرأوا ال [documentation](#) او بتقرأوا تلخيصها على [GitHub](#)
- اخر اشي ب سطر 22 سكرنا الملف
- على سبيل المثال انتوا سيفتوا هاد الملف تاع البايثون ب C:\python_code وبعدين عملت Run للبرنامج اللي كتبناه فوق، هلا ك output عندك ما رح تلاقى، لانه ال output تبغنا ب هاد الكود مش عبارة عن print او هاي الاشياء، لأ، هو عبارة عن ملف csv file اسمه data، طيب وين بلاقيه؟ بتلاقيه بنقس الملف اللي سيفت فيه script البايثون

```

1 from faker import Faker
2 import csv
3
4 output = open("data.csv", "w") # Make a file called "data"
5                                # with csv format to write inside it
6
7 fake = Faker() #Make object from Faker library
8

```

- هي ملف البايثون مع ملف ال data.csv اللى احنا عملناه ب نفس ال file



- الملف اذا فتحتة لازم يعطيك زي هيك:

POSSIBLE DATA LOSS Some features might be lost if you save this workbook in the comma-delimited (.csv) format. To preserve these features, save it in an Excel file format. Don't

	A	B	C	D	E	F	G	H	I
1	name	age	street	city	state	zip	lng	lat	
2									
3	Lynn Steele	72	6887 Stephanie Mission	New Richardton	Arkansas	21637	-9.30071	75.0785535	
4									
5	Joshua Jackson	76	0056 Joshua Ford	Loweport	Alabama	28017	173.003379	-9.2861105	
6									
7	Kelly Swanson	48	13719 Rogers Track Apt. 113	Weberland	Tennessee	20768	-127.560336	60.5957805	
8									
9	George Pitts	29	39325 Jeffery Lodge	New Felicia	Minnesota	79086	141.909261	58.3171775	
10									
11	Melissa Taylor	51	098 Marcia Garden	Ronaldfurt	Illinois	56944	117.142448	88.0030715	
12									
13	Amanda Cameron	59	978 Miller Estates Suite 044	West Tanya	Colorado	30342	-110.107392	86.405711	
14									
15	Angela Mills	30	03580 John Curve Suite 630	New Wesley	Kentucky	22806	42.485803	-68.0597585	
16									
17	Cameron Adams	51	791 Stevenson Meadows Suite 127	Lake Lisa	Rhode Island	77919	116.356987	-11.39933	
18									
19	Jenna Brown	38	6058 Pierce Hill	Amandamouth	New York	80692	-144.049845	39.6967015	
20									

- هلاً احنا اخدنا كيف نكتب ونتعامل مع ال csv files وهلاً رح نوخذ كيف نكتب على ال JSON files

```

1 from faker import Faker
2 import json
3
4 output = open("data.json", "w")
5
6 fake = Faker()
7
8 alldata = {} #Empty dictionary
9 alldata['records'] = [] # Make empty list as a
10                        # value for the "records" key
11
12 for x in range(1000):
13     data = {"name":fake.name(),
14            "age":fake.random_int(min=18,max=80,step=1),
15            "street": fake.street_address(), "city":fake.city(),
16            "state":fake.state(), "zip":fake.zipcode(),
17            "lng": float(fake.longitude()),
18            "lat": float(fake.latitude())}
19     #filling dicionary with values
20
21     alldata['records'].append(data)
22     """append the dictionary to the empty list
23     as a value to the key "recrods" """
24
25 json.dump(alldata, output) #To make the file in JSON format

```

- اول 7 اسطر عارفين شو بعلموا، الفرق الوحيد انه اسم الملف حيكون ب امتداد json لاني انا بدي اعمل json file ويرضه ال library json بتكون نازلة already من anaconda

- سطر 8 عملنا empty dictionary لانه الهيكله تاعة ال json files عبارة عن dictionary ال json file يكون dictionary بشكل كامل، بعدين اول key يكون اسمه records وهاد ال key ال value تاعته بتكون عبارة عن list هاي ال list عبارة عن كل ال records كل record يكون عبارة عن dictionary يعني ب اختصار هي يكون { records : [dictionary, dictionary, dictionary] }

- ب سطر 9 عملنا اول key بال dictionary واسمها records زي ما حكينا وال value تاعته عبارة عن list فاضية وهلا رح ابلس اضيف عليها

- عملنا for loop ب 1000 مرة لاني انه بدي اعمل الف record

- ب كل لفة عم بعمل dictionary وبسميه data وبحط فيه بيانات fake او random، بس طريقة التعباي بتكون على شكل key و value لانه بصله dictionary وال key بده يكون اسم الاعمدة وال value هو الاشئ ال random من ال library

- في شغلة ما شرحناها بالمثال فوق هي شغلة ال random_int، بكل بساطة بدي رقم random تكون اقل قيمة اله 18 واعلى قيمه 80 وال step بدي اياها 1، يعني بدي تعطيني قيمة تكون عبارة 21.5 مثلاً، لأ خلص بدي اياهم integers

- سطر 21 يدي اضيف هاد ال dictionary اللي اسمه data بال list على شكل value لل records ويعمل هاي العملية ب كل لفه ، لانه كل لفه عبارة عن record واحد
- واخر اشي سطر 25 عملنا سيف لهاد الملف على شكل او ال format تاعة ال json files عن طريق dump statement وبعدين بحط جوا الاقواس ال data اللي عندي، وبحالتنا هاي اسمها alldata وبعدين بكتب وين يدي اخزنها، انه ب اي ملف وبحالتنا اسمه output اللي اصلا اسم الملف اللي فيه data.json
- هلا بعمل سيف لملف البايثون زي قبل وبعمل run للبرنامج تاعي ، برضه بلاقي الملف اللي عملته موجود ب امتداد .json. ب امكانك تفتحه عن طريق (for example) notepad → open with → right click وبعدين المفروض يعطيك اشي زي هيك

```

data.json - Notepad
File Edit View

{"records": [{"name": "Karen Scott", "age": 38, "street": "354 Haas Brooks Apt. 316", "city": "Martinshire",
"23860", "lng": 47.625563, "lat": 74.484342}, {"name": "Brandon Vargas", "age": 59, "street": "263 Choi Sprin
ity": "Walterview", "state": "Massachusetts", "zip": "25769", "lng": -87.722868, "lat": 49.8322445}, {"name": "
hnson", "age": 79, "street": "827 Hart Rapids", "city": "North Richardshire", "state": "Illinois", "zip": "85
"Brooke Blankenship", "age": 74, "street": "456 Rowland Flats Suite 026", "city": "Bradleyhaven", "state": "
Wisconsin", "zip": "18777", "lng": 21.705211, "lat": 45.6993495}, {"name": "Lori Wells", "age": 74, "street": "
Harbor Apt. 808", "city": "Walkerfort", "state": "Nevada", "zip": "36732", "lng": -40.068526, "lat": -20.831
Parker Center Suite 528", "city": "Gordonside", "state": "Massachusetts", "zip": "17059", "lng": 110.743069,
"age": 79, "street": "02625 Michele Mount Suite 990", "city": "South Charles", "state": "Tennessee", "zip": "
11.664212, "lat": 11.2866205}, {"name": "Donna Jefferson", "age": 19, "street": "169 Zachary Islands", "city"
y", "state": "Maryland", "zip": "63130", "lng": -133.101282, "lat": -51.462045}, {"name": "Amber Thompson", "
eet": "74792 April Court Suite 085", "city": "Port Matthewfort", "state": "Nevada", "zip": "91093", "lng": 17
me": "Hannah Chung", "age": 55, "street": "00664 Courtney Tunnel", "city": "East Jasminside", "state": "South
2058", "lng": 31.485903, "lat": -11.5532525}, {"name": "Joseph King", "age": 67, "street": "887 Eric Viaduct"
": "Nevada", "zip": "65943", "lng": 6.146211, "lat": 39.786421}, {"name": "Ashley Martinez", "age": 76, "stre
: "Port Matthewbury", "state": "Texas", "zip": "49594", "lng": 174.614928, "lat": -31.97483}, {"name": "Angel
t": "6880 Chad Fords Apt. 160", "city": "North Julieview", "state": "Delaware", "zip": "36444", "lng": 6.7020
name": "Kathryn Blake", "age": 25, "street": "133 Smith Station Suite 904", "city": "New Jameschester", "stat
104.168797, "lat": 44.847116}, {"name": "Eduardo Butler", "age": 40, "street": "0935 Kathleen Junction", "cit
"Tracyport", "state": "Kentucky", "zip": "33193", "lng": -11.159245, "lat": -76.2166165}, {"name": "Leroy Co
e": 18, "street": "24050 Sanchez Mews Suite 723", "city": "Kennethberg", "state": "Texas", "zip": "43521", "l

```

Read CSV file:

```

1 import csv
2 import numpy as np
3
4 with open('data.csv','r') as f:
5     myreader = csv.DictReader(f)
6     header = next(myreader)
7
8     # to find min, max, avg, No. people with age > 40, No. people with age < 20
9     counter = 0
10    age_list = []
11    for row in myreader:
12        if counter %2 ==0:
13            age_list.append(int(row['age']))
14            counter += 1
15
16    age_arr = np.array(age_list)
17
18    print("Minimum age: ", min(age_arr)) # Min
19    print("Maximum age: ", max(age_arr)) # Max
20    print("Average age: ", np.mean(age_arr)) # Avg
21
22    ageGreaterThen40 = age_arr[age_arr > 40] # Age > 40
23    print("No. people with age greater than 40: ", len(ageGreaterThen40),
24 "people")
25
26    ageLowerThan20 = age_arr[age_arr < 20] # Age < 20
27    print("No. people with age lower than 20: ", len(ageLowerThan20) , "people")
28
29 """
30     Output:
31     Minimum age:  18
32     Maximum age:  80
33     Average age:  48.898
34     No. people with age greater than 40:  625 people
35     No. people with age lower than 20:  29 people
36 """

```

- طيب، اول سطرين عملنا import لل packages اللي بنحتاجهم، وبسطر 4 قرأنا الملف (طبعا هاد الملف هو نفسه اللي احنا عملناه قبل عن طريق ال faker باكيچ
- سطر 5 عملت object اسمه myreader وحطيت فيه كل بيانات الملف f (طبعا هاد الملف f هو نفس ملف ال data.csv بس انا سميتاه f (عن طريق as f) عشان اصير اوصله بسرعة زي هون، عن طريق csv.DictReader(file_name)، هلا هاد الفنكشن بحطلي كل البيانات جوا هاد ال variable بس كل record بحطه كل dictionary
- سطر 6 بحكي انه مش ملف ال csv فوق اول اشئ او عمود فيه يكون اسماء ال columns؟ لهيك انا بدئ اخذ هدول الاسماء واحطهم ب variable عن طريق اني انا اعمل next(myreader) ، هاد الفنكشن بعطيني اول

- سطر، وإذا عملت كمان مرة `next(myreader)` فبعطيني ثاني سطر .. وهكذا
- طيب مثلاً علينا تاسك معين اني انا اطلع ال `min, max, avg` وعدد الاشخاص اللي عمرهم اكثر 40، وعدد الاشخاص اللي عمرهم اقل من 20 ف شو لازم اعمل:
 - مبدأياً بدى احط كل هاي الاعداد جوا ليست، بس كيف؟ بدى الف على كل `record` يعني على كل `dictionary` موجود ب `myreader` واطول من ال `value` تابعة ال `age` واحطها جوا ليست
 - ف انا بسطر 9 و 10 عملت `counter` وهلاً بحكيلكم ليش عملته، وعملت ليست فاضية عشان احط فيها الاعداد
 - بسطر 11 لفيت على كل `record` موجود ب `myreader`
 - هلاً الفكرة انه انا حطيت كل القيم رح يكون عندي قيمة فيها عمر وقيمة فيها اشي فاضي، هاد الاشياء الفاضية انا ما بدى اياه، وعندي اذا فتحت الملف رح تلاقي انه `record` فيو بيانات وال `record` اللي بعده فاضي (هلاً هاد هيك هو عندي، ممكن انت ما يكون عندك هاي الفراغات) ف عشان انا ما اخذ هاي الفراغات بدى اياه ينط عن كل ريكورد فردي، وانا بالكود حكتله اذا ال `counter` كان زوجي ف حطلي قيمة ال `age` جوا اللىست، غير هيك لا تعمل اشي، وبعدين اخر اشي جوا ال `for loop` بزيد ال `counter` بواحد
 - عملت `append` لل ليست الفاضية اللي عندي لل `value` تابعة ال `age` اللي موجود ب هاد ال `record` وبعدين حولته ل `int` لانه القيمة لل `age` عبارة عن `string` ف انا بدى احوله ل `int` عشان اقدر اطول منه المعلومات اللي بدى اياها
 - ب سطر 16 حولت هاي اللىست ل `array` عشان اسهل عحالي بعض العمليات
 - ب سطر 18 و 19 و 20 طلت ال `max, min, avg` بسهولة (تذكر بطول ال `avg` عن طريق ال `mean` (method
 - سطر 22 عملت `array` فيو بس القيم اللي اعلى من 40، ببعدين طبعتهم
 - سطر 25 عملت `array` في بس القيم اللي اقل من 20، ببعدين طبعتهم
 - واخر اشي بالكود هاد عبارة عن `comment` فيه ال `output` اللي لازم يطلع معك

Read JSON:

```

1 import json
2
3 with open('data.json','r') as f:
4     data = json.load(f)
5
6 # print(type(data)) # Dict
7 # print(data) # All the records
8 print("first records \n" , data['records'][0], "\n")
9
10 # find min, max, avg
11
12 age_list = [int(record['age']) for record in data['records']]
13
14 print("Minimum age: ",min(age_list))
15 print("Maximum age: ",max(age_list))
16 print("Average age: ", sum(age_list) / len(age_list))
17
18 """Output:
19     first records
20     {'name': 'Karen Scott', 'age': 38, 'street': '354 Haas Brooks Apt. 316',
21 'city': 'Martinshire', 'state': 'Colorado', 'zip': '52135', 'lng': 116.733657,
22 'lat': 17.106047}
23
24     Minimum age:  18
25     Maximum age:  80
26     Average age:  48.988
27 """

```

- هلاً بدنا نعمل نفس الاشئ بس من ملف json ، اول 3 اسطر بنعرف شو بعملوا
- السطر 4 حطيت كل البيانات اللي بالملف بال data variable عن طريق الفنكشن json.load
- ال type لل data variable هو dictionary
- لو بدى اطبع ال data variable ف هو رح يطبعلي كل الملف
- اذا بدى اطول اول record ف بطوله عن طريق data['records'][0] زي ب سطر 8 ، لانه البيانات او ال records هي عبارة عن value لل key اللي اسمه records ف عشان اوصل لل values تاعونه بعمل data['records'] ، ف هلا ال value عبارة عن ليست ، ف اذا بدى اطول اول record بعمل [0] لانه اول record هو عبارة عن اول عنصر ب هاي الليست، لانه ال value تاعة ال records عبارة عن list وكل item او عنصر فيها هو عبارة عن dictionary وكل dictionary هو عبارة عن record (ركزوا بالكلام اللي قبل عشان تفهموا كويس)
- اخر اشئ حطيت الاعداد كلها ب ليست عن طريق اني انا اخذ ال value تاعة ال age واحولها ل int وال ف عكس ال records اللي بال data variable ، بعدين طلعنا القيم اللي هم min,max,avg زي ما عملنا قبل

Lab 1 (Assignment):

1. Convert the JSON FILE (data1.json) to CSV FILE (data1.csv)
 2. Convert the CSV FILE (data2.csv) to JSON FILE (data2.json)
 3. Load the data1 and data2 to df1, df2 dataframes respectively, using numpy as pandas libraries
 4. print the number of the records in df1, and df2
 5. print the average of the salary attribute in the df2
 6. Normalize the age attribute in df2 using z-score normalization, and replace the original one with the normalized one.
- Download [data1.json](#)
 - Download [data2.csv](#)


The Solution:

```
1 # 1) Convert the JSON FILE (data1.json) to CSV File (data1.csv)
2
3 import json, csv #import json and csv libraries
4
5 with open("data1.json", 'r') as json_file_1:
6     data = json.load(json_file_1)
7
8 records = data['records'] #Taking the value for the 'records' element
9
10 with open("data1.csv", 'w') as csv_file_1:
11     writer = csv.writer(csv_file_1) # object for writing inside the file
12     record = records[0] #Taking the first element "first record"
13     writer.writerow(record.keys()) #and write the keys for that element, instead
14 of writing (['id', 'name', 'age', etc])
15     for record in records: #looping inside all the records record by record
16         writer.writerow(record.values()) #writing every record
17
18
19
20 # 2) Convert the CSV FILE (data2.csv) to JSON FILE (data2.json)
21
22 with open('data2.csv', 'r') as csv_file_2:
23     csv_reader = csv.DictReader(csv_file_2)
```

```
24     all_data = {} # null dictionary for making the json file
25     all_data['records'] = [row for row in csv_reader]
26
27 with open("data2.json", 'w') as json_file_2: # open the file, 'w' for writing and
28     creating one if doesn't exist
29     json.dump(all_data, json_file_2) # put all the data inside the json file, using
30     json.dump(all_the_data, the_file)
31
32
33
34 # 3) Load the data1 and data2 to df1, df2 dataframes respectively, using numpy as
35     panda libraries
36
37 import numpy as np
38 import pandas as pd
39
40 df1 = pd.read_csv('data1.csv') # load file1 into pandas dataframe
41 df2 = pd.read_csv('data2.csv') # load file2 into pandas dataframe
42
43
44
45 # 4) Print the number of the records in df1, and df2.
46
47 print("Number of records in df1:", df1.shape[0])
48 print("Number of records in df2:", df2.shape[0])
49
50
51
52 # 5) Print the average salary attribute in the df2
53
54 salary_mean = df2['salary'].mean() # calculate the mean of the salary attribute
55 print("The average of the salary:", salary_mean)
56
57
58
59 # 6) Normalize the age attribute in df2 using z-score normalization, and replace
60     the original one with the normalized one.
61
62 def z_score(attribute):
63     """ Calculate the z-score while z-score = (value - mean) / std
64         and return the values """
65     mean = np.mean(attribute)
66     std = np.std(attribute)
67     return [(value - mean) / std for value in attribute] #return a list with the
68     normalized values
69
70 df2['age'] = z_score(df2['age']) # replace the original with the normalized
```

- التاسك 1: احوال الملف من json ل csv:

- سطر 3 علمنا import لل packages اللي بنحتاجهم بعملية التحويل، واللي همة json, csv
- سطر 5 فتحنا الملف ال json عن طريق with open وكتبنا اسم الملف اللي هو data1.json وبعدين حطيت نوع القراءة r لانه انا بس بدي اقرأ الملف وما بدي اعدل عليه، بعدين اخر اشي حطيت as json_file_1 يعني اعطيت الملف اسم عشان استخدمه انا بالكود (زي لما اعمل import لل pandas (as pd
- سطر 6 حطيت كل بيانات ملف ال json جوا متغير اسمه data عن طريق json.load(json_file_1)
- سطر 8 اخدنا كل البيانات عن طريق ال data['records'] وحطيتهم ب متغير هلاً اذا احنا بنتطلع عال json file اللي عنا بتلاحظوا انه ال structure تاعه كالاتي:
- اول اشي واكبر اشي اللي هو dictionary كبير يعني الملف كله عبارة عن dictionary واحد وهاد ال dictionary اله key واحد اللي هو records وال value لهاد ال key اللي همة ال records يعني اللي همة البيانات
- زي ما حكينا ال value لل key اللي موجود بال dictionary الكبير هو عبارة عن ليست لهيك هاي الليست هي ثاني اكبر اشي ب ملف ال json، طيب هاي الليست شو فيها؟
- بيجي دور ثالث الاشلي اللي هو dictionary صغير، هلاً هاي الليست فيها items كل item هو عبارة عن dictionary وهاد ال dictionary الصغير يمثل ال record
- نرجع للموضوع، هلاً لما انا اخذ ال value لل key اللي اسمه records انا هيكون اخذت ليست فيها dictionary كل dictionary هو عبارة عن record والصورة اللي تحت رح توضحك هاد الاشلي



```

{
  "records": [
    {
      "id": 2,
      "name": "John",
      "age": 25,
      "loc": "NY",
      "Gender": "Male"
    },
    {
      "id": 5,
      "name": "Jane",
      "age": 56,
      "loc": "NY",
      "Gender": "Female"
    },
    {
      "id": 6,
      "name": "David",
      "age": 50,
      "loc": "MN",
      "Gender": "Male"
    },
    {
      "id": 7,
      "name": "FARI",
      "age": 45,
      "loc": "NY",
      "Gender": "Female"
    },
    {
      "id": 15,
      "name": "SARA",
      "age": 60,
      "loc": "NY",
      "Gender": "Female"
    },
    {
      "id": 20,
      "name": "KHAELD",
      "age": 30,
      "loc": "NY",
      "Gender": "MALE"
    },
    {
      "id": 50,
      "name": "MOURAD",
      "age": 40,
      "loc": "NY",
      "Gender": "MALE"
    },
    {
      "id": 18,
      "name": "SENA",
      "age": 56,
      "loc": "NY",
      "Gender": "Female"
    },
    {
      "id": 19,
      "name": "MARYAM",
      "age": 89,
      "loc": "NY",
      "Gender": "Female"
    },
    {
      "id": 17,
      "name": "DANI",
      "age": 40,
      "loc": "NY",
      "Gender": "MALE"
    },
    {
      "id": 21,
      "name": "IEAD",
      "age": 44,
      "loc": "NY",
      "Gender": "MALE"
    },
    {
      "id": 36,
      "name": "BASEM",
      "age": 40,
      "loc": "CH",
      "Gender": "Female"
    },
    {
      "id": 45,
      "name": "DERAR",
      "age": 40,
      "loc": "NY",
      "Gender": "MALE"
    },
    {
      "id": 7,
      "name": "JAMEEL",
      "age": 70,
      "loc": "NY",
      "Gender": "MALE"
    },
    {
      "id": 56,
      "name": "HANI",
      "age": 50,
      "loc": "CH",
      "Gender": "MALE"
    }
  ]
}

```

- سطر 10 قرأنا ملف ال csv عن طريق ('data1.csv','w') with open و w لانه احنا بدنا نعمل write عالملف واذا ما كان في ملف بهاد الاسم يعمل create لواحد دايركت as csv_file_1 زي ما حكينا قبل هي تمسية للملف عشان اسمتخدمه بالكود
- سطر 11 هو عبارة عن object وظيفته انه يكتبلي علف ال csv عن طريق اني اطول من ال package csv فنكشن writer واحط جواه اسم الملف اللي بدي اكتب عليه (لاحظ كتبت اسم الملف عن طريق الاسم اللي سميت اياه فوق (اللي هو csv_file_1) ، ف اذا بدي اكتب عالملف لازم اكتب عليه عن طريق ال object اللي اسمه writer
- سطر 12 اخدنا اول عنصر من الليست الكبيرة، واول عنصر هو عبارة عن dictionary ف زي كاني انا اخدت record واحد من هاي البيانات وحطيتها بتمغير اسمه record، وهلا بتعرفوا ليش انا عملت هيك
- سطر 13 بدي اطبع او اكتب اول سطر ع ملف ال csv ودايما اول سطر يكون ال headers اللي همة اسماء ال columns لهيك انا عندي طريقتين اني اكتب ال header الاولى اني انا اكتب اسماء ال columns ب ايدي جوا ليست يعني زي هيك: ['id','name','age',....] writer.writerow او الطريقة الثانية واللي هي الاسهل، مش انا اخدت record واحد فوق وسميت المتغير اصلا record؟ هلا هاد ال record ال keys تاعته هي نفسها اسماء ال columns اذا بترجع تطلع عالصورة فوق بتشوف انه ال keys تاعه اي record هي عبارة عن اسماء ال headers لهيك بقدر بسهولة اني احط ال record.keys() وطبعا اذا بدي اكتب ع ملف ال csv بستخدم ال object اللي انا عملته قبل شوي وبطول منه الفنكشن writerow وبحط جوا الاقواس ليست بالاسماء او الاشياء اللي بدي اعبي فيها السطر
- سطر 15 عملت for loop بتلف عكل عنصر بالليست (وكل عنصر هو عبارة عن dictionary وكل dictionary هو عبارة عن record) لهيك عملت for record in records وبعدين جواها بدي اياه تطبعلي كل سطر، يعني بدي اياك تعبيلي الاسطر بال values تاعة كل dictionary انت بتلف عليه، لانه انا ما بدي اضيف ال dictionary زي ما هو او ما بدي اضيف ال keys تاعة ال dictionary انا بس بدي اضيف ال values تاعة ال dictionary، واذا بتطلع الصورة فوق بتشوف انه احنا بهد ما كتبنا ال header اللي همة اسماء ال columns ف بعدين كل الاسطر اللي بنحتاجها تحتهم هي عبارة عن values

- التاسك 2: تحويل ملف ال csv ل json:

- سطر 22 قرأت الملف و r عشان بديش اعدل عليه واعطيته اسم csv_file_2
- سميت متغير اسمه csv_reader هاد المتغير فيه كل record على شكل dictionary عن طريق ال csv.DictReader(csv_file_2) من اسمها DictReader يعني بتقرأ ال records على شكل dictionaries

○ سطر 24 عملنا dictionary فاضي لانه احنا حكيينا فوق انه ملف ال json هو عبارة عن dictionary كبير

- بسطر 25 لما عملنا all_data['records'] ف انا زي هيك كأنني حطيت key جوا هاد ال dictionary والقيمة او ال value تاعة هاد ال key اللي هي ليست فيها dictionaries لما عملنا هيك [row for row in csv_reader] هاي اسمها ال list comprehension انها انا عملت ليست كبيرة حطيت فيها كل مرة row هاي ال row هي عبارة عن dictionary اللي هي ال record بحد ذاته
- سطر 27 فتحت او عملت ملف data2.json من نوع w يعني write عشان بدي اطبع عليه واعطيته اسم برضه json_file_2
- هلا ب سطر 29 ف انا هون بعمل انه بنقل كل هاي البيانات (اذا بتلاحظوا انا كل بيانات ملف ال csv حطيتها جوا متغير اسمه all_data لهيك عشان انا بس احط هاي ال data ب ملف json بستخدم json.dump(all_data,json_file_2) هاي فنكشن بتساعدني حط ال data اللي عندي على شكل ال json او بنفسه ال format تاعة ال json files

- تاسك 3: بدي اقرأ الملفات على شكل dataframes:

- سطر 37 و 38 عملنا import ل numpy و pandas
- سطر 40 و 41 قرأنا الملفات اللي عملناها على شكل csv عن طريق pd.read_csv و هاد فنكشن بال pandas بقرألي الملفات اللي من نوع csv وبخط جوا الاقواس اسم ال file اللي بدي اقرأه (بشرط انه يكون موجود بنفس مكان ملف البايثون اللي بشتغل عليه)

- تاسك 4: بده اطبع عدد ال records بكل dataframe:

- بستخدم ال df.shape والناتج او ال output لهاد الفنكشن هو عبارة عن tuple محطوط فيه (rows,columns) بس انا بس بدي اطول ال rows اللي همة نفسهم ال records لهيك بدي اطول اول عنصر من هاد الناتج، وبطول اول عنصر عن طريق اني اختار ال index 0 اللي هي بتمثللي عدد ال records

- تاسك 5: اطبع ال avg ل عمود ال salary اللي بال df2:

- بقدر اطبع ال average او ال mean عن طريق اني اكتب اسم ال dataframe واطول ال column اللي بدي اطول ال mean تاعه بعدين بخط (mean()). وبس

- تاسك 6: اعمل normalization لل column اللي اسمه age اللي بال df2 باستخدام ال z-score وارجع اعيد كتابة العمود بالقيم الجديدة اللي معموللها normalization وجاهزة

- في قانون ال z-score الي هو لكل نقطة بطرح منها ال mean للعمود بعدين بقسمها على ال std تاع العمود كامل والقيمة الناتجة هي القيمة بعد ما نعمللها normalization

- سطر 62 عملت فنكشن اسمه z-score رح يدخل فيه attribute اللي بدي اعملها normalization
- سطر 63 و 64 عبارة عن multi line comment
- سطر 65 بطلع ال mean للعمود عن طريق np.mean(attribute) وبخزنها بمتغير
- سطر 66 بعمل نفس الاشئ لل std
- سطر 67 بعمل ليست هاي الليست القيم رح تكون فيها عبارة عن كل قيمة بال attribute الاصلية وبطرح منها ال mean اللي طلعت فوق وبعدين بقسمها عال std، كل القيم رح تدخل بهاد القانون، بالتالي الناتج او ال output او ال return من الفنكشن عبارة عن ليست معمول للقيم اللي داخلة فيه normalization عن طريق ال z-score
- سطر 70 بدي اعمل replace للعمود الاصلي عن طريق اني اعمل
`df2['age'] = z_score(df2['age'])` ف هون انا بعمل overwrite لعمود ال age بالناتج الطالع من
 الفنكشن z_score اللي عملته
- بتقدر تشوف الكود برضه [من هون مع شوية كومنترات](#)

Downloading ubuntu on windows:

1. Download Virtual Box from [here](#)
2. Download the Ubuntu image from [here](#)
3. Connect the Ubuntu image to the virtual box, watch [this video](#) to learn more

Downloading Airflow on Ubuntu:

- Follow the instructions [here](#)

Importing CSV:

```

1 import pandas as pd
2 pd.options.display.float_format = '{:.2f}'.format
3 pd.set_option('display.width',75)
4 pd.set_option('display.max_columns',20)
5
6 landtemps = pd.read_csv("./data/landtempssample.csv",
7                          names= ['stationid','year',
8                                  'month','avgtemp',
9                                  'latitude','longitude',
10                                 'elevation','station',
11                                 'countryid','country'],
12                                skiprows=1,
13                                parse_dates = [['month','year']],
14                                low_memory=False)
15
16 type(landtemps) # pandas dataframe
17
18 # show enough data to get a sense of how the import went
19 landtemps.head(7) # first 7 rows
20 landtemps.dtypes # show the datatypes for every column
21 landtemps.shape # show the shape for the dataframe
22
23 # fix the columns name for the data
24 landtemps.rename(columns={"month_year":"measuredate"}, inplace=True) # rename the
25 column name
26 landtemps.dtypes # show datatypes for every column
27 landtemps.avgtemp.describe() # show basic information about the column
28 (count,mean, std,min,max...)
29 landtemps.isnull().sum() # show how many null values in every column
30
31 # remove rows with missing values
32 landtemps.dropna(subset=['avgtemp'],inplace=True) #dropping the the record which
33 their avgtemp value is null
34 landtemps.shape

```

- أول 4 اسطر فوق هي عبارة عن تعديل شوية تعديلا بطريقة عرض البيانات ، وهي ابدأ مش ضرورية، يعني بقدر انت تشوف وتستخدم البيانات من دون ما تلعب بهاي الاعدادات، بس خنشرهم يعني:

○ سطر 2 هي عبارة عن اني انا اعرض الارقام ال float بس خانتين من بعد الفاصلة، عن طريق اني انا اعمل {:.2f} وال 2 بعد. بتعني انه بدي اياك تعرض اول خانتين من ال float number وال f هي عبارة عن انه هاد الرقم حيكون float

○ سطر 3 هو اني انا اغير ال width لل column، وهي شغلة مش ضرورية صراحة، لانه ال IDE اللي احنا بنستخدمهم همة بعملو autodetect لل width وبحطوه، و by default يكون 80

○ سطر 4 احكيه كم من column تعرضي لما انا بدي اشوف ال head مثلا، مثلا انا عندي dataset فيها 100 عمود، حيكون صعب انه ال IDE يعرضلي اياهم كلهم، لهيك مثلا انا بحددله انا ال

maximum columns يكون 20، ف هو بظهوري 20 عمود وبخبي الباقي

- سطر 6 عملنا متغير سميناه landtemps ، وهاد المتغيره حيكون عبارة عن dataframe وحنقرأ ال داتا تاعتنا عن طريق ال read_csv لانه المف بصيغة csv، بعدين بحط ال path ل مكان وجود البيانات (انا هون عملت ./data/landtempssample.csv لانه البيانات موجودة جوا فايل مسميه data وهاد الفايل موجود بنفس مكان ملف الباينون)
- ال names بحط فيها اسماء ال columns اللي انا بدي اياهم بال داتا اللي عندي، ولازم شرط اساسي انه يكون عدد الاسماء نفس عدد الاعمدة وب نفس الترتيب (ملاحظة: بحط اسماء الاعمدة الجديدة جوا ليست)
- ال skiprows من اسمها بتعمل skip للاسطر من فوق، وانا حطيت 1 لانني ما بدي اياه يقرألي اول سطر اللي هو ال headers لانني انا اوريدي حطيت اسماء لل columns مني عن طريق ال names method
- ال parse_dates هي بتدمجلي اكثر من عمود الهم علاقة بالوقت (ان وجد، يعني اذا كان في همود واحد رضه مش مشكلة) وبتحوللي ال data type لهاد العمود ل time، يعني بصير اقدر اتعامل معاه بطريقة more flexible ملاحظات مهمة:
- اذا كان عندي اكثر من عمود الهم دخل بالوقت ف بحطهم ب nested list يعني زي ما عملت انا فوق `[[‘month’,‘year’]]`
- اذا كان عندي اكثر من عمود وحطيتهم ب هاي ال statement ف ال output او الناتج حيكون عبارة عن column واحد، يعني بدمجلي العمودين مع بعض
- هون انا عندي بس ال month وال year بس ما عندي ال day لهيك ال pandas رح تعمل ال day يكون 1 by default
- ال low_memory الفكرة تاعتها انه اذا انا عندي داتا كثير كبيرة ف pandas by default يكون حاططها True، انه اذا الداتا كبيرة ف بدي اياك تستخدم مساحة قليلة من ال memory عن طريق انه يقسم ال data ل patches
- بس اذا كانت قيمتها False ف بحمل كل البيانات ويمكن يسحب كمية كبيرة من ال memory من الجهاز تاعك واللي ممكن يسبب ب بطء بالجهاز
- سطر 16: بعطيني ال type لل landtemps واللي هو pandas dataframe
- سطر 19: بعطيني اول 7 records ، ولو ما حطيت رقم ف رح يعطيني اول 5 تلقائيا
- سطر 20: بعطيني ال data types لكل column بال dataframe
- سطر 21: بعطيني حجم ال dataframe اللي عندي على شكل (rows, columns) وال output من ال shape. عبارة عن tuple
- سطر 24: بدي اعمل rename لل column الناتج من دمج ال year وال month، لما دمجهم حط اسمهم month_year ف انا بدي اغيره عن طريق ال rename. وكتب columns عشان احدد انه انا بدي اغير بالاعمدة، وبحط ال value لل columns اللي هو dict ال key عبارة عن الاسم القديم وال value عبارة عن

الاسم الجديد، بعدين اخر اشي عملنا inplace=True لانه لما ما عملت True رح يتغير اسم ال column بس انه بشكل مؤقت، يعني لو رجعت بدي اشوف ال head ف رح تلاقي انه ما تغير اسم العمود لاني انا ما عملت inplace=True ، ف هاي وظيفتها انه انا اذا بدي اغير اشي عال dataframe بشكل دائم لازم اعمل inplace=True ولو ما حطيت هاي ال inplace كلها ف هي بتكون محظوظة قيمتها by default False انها

- سطر 27: هون انا بعمل شوية descriptive analysis للعمود ال avgtemp عن طريق ال .describe() هاي بتعطيني معلومات اساسية عن هاد ال column زي ال min, max, avg, 25%,50%,75%,count,mean,std ولو ما حطيت انه انا بدي بس لهاد ال column يعني landtemps.describe() ف رح يطلعلي هاي المعلومات لكل ال columns. (ملاحظة: لما بدي اطول عمود معين بناديه ب اسمه اللي انا سميته فوق جوا ال names مش ب اسم ال column جوا ملف ال csv نفسه)

```
Out[46]:
measuredate      0
stationid         0
avgtemp          14446
latitude          0
longitude         0
elevation         0
station           0
countryid         0
country           5
dtype: int64
```

- سطر 29: هاد بعمل sum للعدد ال null values لكل column بال dataframe وال output سيكون زي هيك: فهون بحكي لي انه عمود ال avgtemp فيو 14446 قيمة فاضية وال country فيو 5 والباقي صفر ، يعني كلهم مليونيين او ما فيهم null_values

- سطر 32: dropna بتعملي drop يعني بتحذف ال records اللي فيهم null values، بس هون احنا حطينا subset القيمة فيها ['avgtemp'] يعني بدي اياك تشطب ال records اللي فيهم null values بالعمود avgtemp، يعني اذا عمود ال country فيه null value ب record معين بس ما في null value بهمود ال avgtemp ف مش رح يحذف هاد ال record لانه انا محدله بتحذف ال record بحال بس اذا ال avgtemp فيه null value، بعدين عملت inplace عشان اثبت هاد الاشي واخليه دائم مش مؤقت

- سطر 34: برجع بطبع ال shape لهاي ال dataframe وكيد رح ينقص عدد ال records عن قبل لاني عملت drop لل null values الموجودات ب عمود ال avgtemp، بس عدد ال columns ثابت

- بتقدر تنزل هاي ال dataset عشان تشتغل عليها براحتك [من هون](#)

Importing Excel:

```


1 import pandas as pd
2 pd.options.display.float_format = '{:.0f}'.format
3 pd.set_option('display.width',85)
4 pd.set_option('display.max_columns',20)
5
6 # import the land temperature data
7 percapitaGDP = pd.read_excel("./data/GDPpercapita.xlsx",
8                               sheet_name = "OECD.Stat export",
9                               skiprows = 4,
10                              skipfooter = 1,
11                              usecols = "A, C:T")
12
13 percapitaGDP.head()
14 percapitaGDP.info()
15
16 # rename the Year column to metro
17 percapitaGDP.rename(columns={'Year':"metro"}, inplace=True)
18 percapitaGDP.metro.str.startswith(' ').any() # returns boolean value
19 percapitaGDP.metro.str.endswith(' ').any() # return boolean value
20 percapitaGDP.metro = percapitaGDP.metro.str.strip()
21
22 # convert the data columns to numeric
23 for col in percapitaGDP.columns[1:]:
24     percapitaGDP[col] = pd.to_numeric(percapitaGDP[col], errors='coerce')
25     percapitaGDP.rename(columns={col:"pcGDP" + col}, inplace= True)
26
27
28 percapitaGDP.head()
29 percapitaGDP.dtypes
30 percapitaGDP.describe()
31
32 # remove rows where all of the per capita GDP values are missing
33 percapitaGDP.dropna(subset = percapitaGDP.columns[1:], how = 'all', inplace=True)
34 percapitaGDP.describe()
35 percapitaGDP.head()
36 percapitaGDP.shape
37
38 # set an index using the metropolitan area column
39 percapitaGDP.metro.count()
40 percapitaGDP.metro.nunique()
41 percapitaGDP.set_index('metro',inplace=True)
42 percapitaGDP.head()
43 percapitaGDP.loc['AUS02: Greater Melbourne']

```

- نبليش، ب اول 4 اسطر بنعرف احنا شو بعملوا، بس الفرق انه بالسطر الثاني خط انه ما يطلعلي ولا خانة اذا كان الرقم float عن طريق ال {:.0f}

- ب سطر 7 قرأنا ال dataset عن طريق pd.read_excel لأنه الملف بصيغة excel اللي هي .xlsx

○ حطيت ال path بالمكان اللي فيه الداتا



○ سطر 8، احنا بنعرف انه بال excel file ممكن يكون في اكثر من sheet لهيك انا بختار ال sheet اللي بدي اطول منها البيانات، ويكتب اسمها بالزبط زي مهو بالملف، وبحالتنا اسم ال sheet هو OECD.Stat export

	A	B	C	D	E
2	Dataset: Metropolitan areas				
3	Variables	GDP per cap			
4	Unit	US Dollar			
5	Year	2001	2002	2003	
6	Metropolitan areas				
7	AUS: Australia				
8	AUS01: Greater Sydney	43313	44008	45424	

○ سطر 9 بحكيه اني بدي اعمل سكيب ل اول 4 اسطر، ليش؟ لأنه اول 4 اسطر عبرة عن اسطر ما الها دخل الداتا، او انه الها دخل بس هي مش عبارة عن بيانات، وانا بدي استخدم البيانات واخدها، بديش اشي ثاني

■ بتلاحظوا انه ما في رقم 1 بال rows؟ ليش؟ لأنه ممكن ب بعض المرات يكون في اسطر مخفية، وهي هون مبين انه السطر 1 مخفي، طيب كيف نشوفه؟ اكبس right click على رقم 2 اللي هو السطر الثاني، وبعدين في يكون خيار unhide اكبس عليه وببينك السطر المخفي

705	USA167: Weber	34592	34997	35587	357
706	USA169: Cass	44597	46856	49043	491
707	USA170: Benton (AR)	41988	44687	45296	477
708	Data extracted on 05 May 2020 10:55 UTC (GMT) from OECD.Stat				
709					
710					
711					
712					

○ سطر 10 من اسمها skip footer ، مرات برضه يكون في اسطر اخر الملف ما محتاجها لهيك بعملها سكيب، والسكيب يكون بطريقة عكسية، انه اذا حطيت سكيب 2 يعني رح يعمل سكيب عن اخر سطرين وهكذا، زي هون بالصورة بتلاحظوا انه هاد الاسطر اللي بالاخير انا ما باستفيد منه

#	A	B	C	D	E	F	G	H	I	J	K
1	#NAME?	Sorry, the query is too large to fit into the Excel cell. You will not be able to update your table with the Stat Populator.									
2	Dataset: Metropolitan areas	POP per 100	Year	US Dollar							
3	Year	2001	2002	2003	2004	2005	2006	2007	2008	2009	
4	Metropolitan areas										
5	AUS: Australia										
6	AUS01: Greater Sydney	43313	44008	45424	45837	45423	45547	45880	45225	45900	
7	AUS02: Greater Melbourne	40122	40894	40664	40188	41424	41599	42214	40914	41464	
8	AUS03: Greater Brisbane	37580	37564	39050	40782	42376	44475	44635	46192	43007	
9	AUS04: Greater Perth	42713	47311	48718	51020	50378	50142	52651	53899	53616	
10	AUS05: Greater Adelaide	36505	37194	37634	37399	37804	38151	39049	38502	39538	
11	AUS06: Gold Coast										
12	AUS07: Canberra	41465	44028	44814	45675	46024	46578	46699	48919	51358	
13	AUS08: Newcastle										
14	AUS10: Wollongong										
15	AUS11: Sunshine Coast										
16	AUS14: Geelong										
17	AUT: Austria										
18	AT001: Vienna	52504	53172	52675	53496	53686	55215	56330	56900	54930	
19	AT002: Graz	40299	40154	40119	41713	40535	40256	50898	51934	48945	
20	AT003: Linz	47110	47031	47942	48029	49670	51364	52841	54883	52092	
21	AT004: Salzburg	44493	44494	44498	46968	47819	48254	48198	49998	49602	
22	AT005: Innsbruck	49065	49467	49820	50425	52055	53372	54573	54470	52388	
23	AT006: Klagenfurt	38819	39580	40049	41224	42746	43514	43746	45932	43198	
24	BEL: Belgium										
25	BE001: Brussels	58117	60383	60383	68411	69696	70413	71028	71526	70835	
26	BE002: Antwerp	50822	51662	51561	53763	56093	56609	58313	58391	54150	
27	BE003: Gent	44247	45470	46881	48814	49648	49490	51984	51064	49561	
28	BE004: Charleroi	29320	29106	29627	30548	31005	31519	32357	33037	31282	
29	BE005: Liege	31944	32090	32678	33749	34440	35263	36078	36009	35542	
30	CAN: Canada										
31	CAN01: Toronto									43804	
32	CAN02: Montreal									34085	

- سطر 11 usecols اختصار ل use columns
بملف الاكسيل في اعمدة بتكون فوق فوق مسمية
ب A, B, C, الخ، مرات في يكون اعمدة انا ما
بحتاجها، او اعمدة فاضية، ف انا ما بدي
استخدمها، ليهيك انا من خلال usecols بقدر اسمي
الاعمدة اللي بدي اياها، زي هون مثلا بالداتا سيت
اللي عنا، العمود B هو عبارة عن عمود فاضي،
ف انا ما بدي اياه وما بدي احطه بال
dataframe اللي بدي اشتغل عليها ليهيك كتبت
usecols = "A, C:T" انه اختار لي العمود A،
بعدين ادخل ب رينج ودخلي الاعمدة من C ل T

- سطر 13 بعطيني اول 5 records بال داتاسيت اللي عندي

- سطر 14 بتعطيني info(). معلومات عن كل عمود زي عدد ال none null values وال datatype لهاد العمود

- اذا بتلاحظوا عمود ال year تحته اسماء مدن ف ليهيك مش منطقي انه يكون اسم العمود year ليهيك احنا بدنا نغيره عن طريق ال rename. وبحط اسم العمود القديم بعدين الجديد as a dictionary وبعدين بعمل inplace=True عشان اثبت هاد التغيير واخليه تغيير دائم مش مؤقت

- هلا بعد مغيرنا اسم العمود من year ل metro بنلاحظ انه في شوائب كثير بالاسم ك string زي انه في فراغات قبل الاسم او بعده، هاد كله لازم نتخلص منه وعملية التخلص منه اسمها data cleaning، طيب، هلا كيف بدنا نشيل الفراغات القبل واللي بعد، اول اشي بدنا نتأكد اصلا اذا في فراغات قبل وبعد، كيف؟ عن طريق اني انادي ال dataframe بعدين انادي اسم العمود اللي هو metro بعدين بنادي str. عشان اخذ خصائص ال string واقدر اوصل للي بدي اياه، بعدين في method بال str اللي هي startswith() وبتحط جوا الاقواس ايش الاشياء اللي انت بتدور عليه اول الاسم (بحالتنا رح يكون فراغ او space " ") بعدين بحط any(). عشان انا بدي اعرف انه اذا في بس اسم واحد في ب قبله فراغ، ف لو كان بس اسم واحد ب قبله فراغ حيعطيني True ولو كانوا كلهم برضه حيعطيني True ولو ما كان ولا وحدة فيهم بتطبق عليها الشرط وقتها حيعطيني False، ولازم نعرف انه ال methods اللي همة startswith() و endswith() هتدول برجعولي Boolean value يعني بعطوني True او False ف بسطر 18 و 19 طبقت هاد الاشياء، ورح يرجعولي التنتين True يعني في spaces ببعض ال records قبلها وبعدها، ليهيك انا بعد ما عرفت هاي المعلومة، وقتها باجي اتخلص منهم

- بدي اعمل overwrite للقيمة الاصلية بالقيمة الجديدة اللي انا زبطتها، عن طريق اني انا اعطي value لهاد العمود وهاي ال value هي نفي العمود بس بعد ما عملته clean وكيف بعمله clean؟ بنادي العمود من الداتاسيت وبعدين بنادي ال str. عشان اقدر اوصل لل فنكشن اللي رح يعمللي cleaning واللي هو strip() هاد الفنكشن بنادي به بعد ال str. وبشيللي الفراغات اللي قبل الكلمة وبعدها، هو by default رح يكون ال قيمة اللي بده يشيلها قبل وبعد ال space بس مثلا لو انت بدك اشي ثاني مثلا * بتقدر تحطها جوا الاقواس زي هيك strip("*"). وبشيل كل ال * اللي قبل الاسم وبعده

- هلاً لما عملنا `percapitaGDP.info()` بنلاحظ انه ال `dtype` لل `columns` عباره عن `object` لهيك
انا لازم اغيره لانه لازم يكون عبارة عن ارقام او `integers` او `float`
وفي عندي كمان مشكلة انه اسماء الاعمدة عندي بال `dataframe` عبارة عن `integers` وهاد اشئ
ممنوع بالبايثون، لازم يكون اسماء الاعمدة `string` لانه لو مثلاً بدي انادي العمود 2012 زي هيك
`percapitaGDP[2012]` ف هو بهاي الحالة حيفكر انها `index` مش اسم عمود، لهيك لازم نغيره،
واحنا رح نغيره بطريقة انه نلف عالاسم واحد واحد ونضيف قبله كلمة `pcGDP`
- طيب، بسطر 23 لفينا عالعمدة كلهم ماعدا اول واحد، لانها اول واحد جاهز وما بدي اغير فيه اشئ وال
`values` تاعته مزبوطات والاسم تاعه برضه مزبوط، لهيك بلف عليهم كلهم ماعدا اول واحد عن طريق
`for col in percapitaGDP.columns[1:]` انه لفل عكل الاعمدة دون اول واحد
- بعدين بلف ع كل عمود بال `dataframe` وبحول محتوياته ل `numeric` عن طريق `pd.to_numeric`
وبحط جوا اسم العمود من ال `dataframe` وبعدين نوع ال `error` حيكون `coerce`، هاي شو معناها؟
معناها هاي معناها انه اذا فيه `value` انت ما عرفت تحولها ل `numeric` ف حولها ل `NaN` يعني
`value`، لانه اذا بتلاحظوا في بالبيانات ال `value` بتكون عبارة عن ف هاي قيمة ما بزبط انه يحولها
ل `numeric` لهيك بحولها ل `NaN`
- بعدين برضه جوا ال `for loop` بغير اسم العمود عن طريق اني اضيف كلمة `pcGDP` قبل كل اسم
`column` وبعدين بعمل `inplace=True`
- سطر 28 ل 30 بنعرف شو بعملوا
- ب سطر 33 بدي احذف ال `records` اللي فيهم `null values` بحيث انه كل ال `columns` تكون القيمة
تاعته `null`، يعني.....

		Unit US Dollar																	
	Year	2001	2002	2003	2004	2005	2006	2007	2008	2009	2010	2011	2012	2013	2014	2015	2016	2017	2018
5	Metropolitan areas																		
6	AUS: Australia																		
7	AUS01: Greater Sydney	43313	44008	45424	45837	45423	45547	45880	45225	45900	45672	46535	47350	47225	48510	50075	50519	50578	49860
8	AUS02: Greater Melbourne	40125	40894	41602	42188	41484	41589	42316	40975	41384	40943	41165	41264	41157	42114	42928	42671	43025	42674
9	AUS03: Greater Brisbane	37580	37564	39080	40762	42976	44475	44635	46192	43507	42774	44166	43764	43379	43754	44388	45723	46876	46640
10	AUS04: Greater Perth	45713	47371	48719	51020	52978	56142	52551	53899	53616	55111	57118	57679	56153	57555	58544	60302	60424	70399
11	AUS05: Greater Adelaide	36505	37194	37634	37399	37604	38151	39049	38502	39538	39309	39223	39812	39855	40306	40295	39737	40115	39924
12	AUS06: Gold Coast																		
13	AUS07: Canberra	41465	44028	44814	45675	46024	48578	49689	48919	51358	51364	52801	54049	53206	54503	56421	55979	56301	55971
14	AUS08: Newcastle																		
15	AUS10: Wollongong																		
16	AUS11: Sunshine Coast																		
17	AUS14: Geelong																		
18	AUT: Austria																		
19	AT001: Vienna	52504	53172	52675	53486	53686	55218	56330	56000	54930	55335	55794	55150	54468	53992	53885	54575	54426	54890
20	AT002: Graz	45259	45124	46119	47713	48535	49295	50895	51204	48945	49218	50628	51060	50349	50492	50190	51332	52441	53155
21	AT003: Linz	47110	47031	47942	48529	49870	51364	52841	54883	52092	52903	54111	53941	53994	53792	54330	54387	55553	56340
22	AT004: Salzburg	53464	54095	54493	55855	57859	60224	59078	59598	59627	62114	63714	64752	65053	63784	63893	64748	65662	66995
23	AT005: Innsbruck	49065	49467	49820	50425	52055	53372	54573	54470	52388	52617	53621	54087	54019	53602	54067	54289	54996	55176
24	AT006: Klagenfurt	38875	39592	40049	41224	42746	43514	45746	45932	43198	44284	45911	45361	44742	45004	44729	44691	45797	47109
25	BEL: Belgium																		

اذا بتلاحظوا هون، الاعمدة من 2001 ل 2018 ب بعض ال `records` كلها بتكون فاضية، هون كانت
عبارة عن "...." بس قبل شوي غيرناها ل `NaN` لهيك في بعض الاسطر حيكون كل الاعمدة فيها تاعة
التواريخ `null values`، هون بدي احذفهم، انا كيف خليته يشطب بس ال `records` اللي فاضي فيهم
كل الاعمدة؟ عن طريق 'all' = `how` (ملاحظة انه انا ما اخدت اول عمود لانه هاد عالاكيد كله رح
يكون معبأ، لانه هاد بمثابة `index` وبعد شوي حنشوف كيف حنحطه ك `index`) واخر اشئ بعمل
`inplace=True` عشان اثبت حذف الاسطر واحذفهم بشكل كامل

- من سطر 34 ل 36 بنعرف شو بعملوا

- سطر 39 ال count() بتعطيني كم من value موجودة بهاد العمود
- سطر 40 ال nunique() بتعطيني عدد ال unique values بهاد العمود
ولو كان عدد ال unique values يساوي عدد ال count بهاد العمود ف بزبط معي اني احطه ك index لانه unique وما بتكرر
- ب سطر 41 بدي احط عمود ال metro ك index عن طريق
percapita.set_index('metro',inplace=True) بحط جوا الاقواس اسم العمود اللي بدي اخليه index وما بنسى اعمل inplace=True عشان اثبت هاد الاشئ واخليه دائم
- ب سطر 42 بعرضلي اول 5 اسطر
- ب سطر 43 بطول ال record اللي ال index فيه اسمه "AUS02: Greater Melbourne" ب استخدام ال loc. وهاي بحط جواها اسم ال index اللي بدي اطوله، والنتائج او ال output لهاي الجملة
حيكون عبارة عن record واحد كامل
- بتقدر تنزل الداتا عندك [من هون برضه](#)

Importing SQL:

```

1 # import pandas, pymysql, and mysql
2 import pandas as pd
3 import numpy as np
4 import pymysql
5 import mysql.connector
6 pd.set_option('display.width', 75)
7 pd.set_option('display.max_columns', 5)
8 pd.options.display.float_format = '{:,.2f}'.format
9
10 # set sql select statement to pull the data
11 query = "SELECT studentid, school, sex, age, famsize,\
12     medu AS mothereducation, fedu AS fathereducation,\
13     traveltime, studytime, failures, famrel, freetime,\
14     goout, g1 AS gradeperiod1, g2 AS gradeperiod2,\
15     g3 AS gradeperiod3 From studentmath"
16
17 # use the pymysql api and read_sql to retrieve and load data from a SQL
18 Server instance
19 server = "pdcc.c9sqqzd5fulv.us-west-2.rds.amazonaws.com"
20 user = "pdccuser"
21 password = "pdccpass"
22 database = "pdctest"
23 conn = pymysql.connect(server=server,
24     user=user, password=password, database=database)
25 studentmath = pd.read_sql(query, conn)
26 conn.close()
27
28 # use the mysql api and read_sql to retrieve and load data from mysql
29 # this will result in the same file as with the pymysql
30 host = "pdccmysql.c9sqqzd5fulv.us-west-2.rds.amazonaws.com"
31 user = "pdccuser"
32 password = "pdccpass"
33 database = "pdccschema"
34 connmysql = mysql.connector.connect(host=host,
35     database=database, user=user, password=password)
36 studentmath = pd.read_sql(sqlselect, connmysql)
37 connmysql.close()

```

- طيب، هالأ الفكرة هون انه انا بدي اطول داتا من سيرفرات خارجية وهون رح نستخدم 2 packages اللي همة

pymysql و mysql

هالأ ال pymysql هي باكيج لل Microsoft server SQL

وال mysql هي لل MySQL

- عملناهم import وكلشي تمام، بس لاحظا انه ال mysql طلنا منها ال connector

- طيب يعني هالأ احنا بنعرف اول 9 اسطر شو بعملوا و ل ايش

- سطر 11 هو عبارة عن ال query الذي يدي اعملها عال databases، هلاً احنا في حنا داتابيس كبيرة وفي اشياء بلاوي وسيرفرات وقصص، ليهك انا لما بدي اطول بيانات لازم اعرف انا شو بدي اطول، وعشان اطول بيانات من سيرفرات خارجية
انا عندي بالداتابيس داتا انا بدي اطول منها عمود عمود، ف بكتب بال query اسماء ال columns الذي بدي اطولهم عن طريق ال select statement الذي احنا بنعرفها بال sql
بعد ال select بكتب اسماء الاعمدة، عمود عمود، واذا حطيت بعده AS هاي معناها انه طوللي هاد العمود وحطلي اياه بالداتافريم بالاسم الذي بعد ال AS
بس اخلص بكتب From وبعدها بكتب اسم ال table الذي انا حطول منها هاي ال columns
واخر اشي مهم انه هاي ال query انا حطيتها ب string يعني انا لسا ما نفذتها ولا اشي
- سطر 19 ل 22 هي عبارة عن معلومات ال server الذي انا حطول منه هاي البيانات، بس بنقدر نستنتج معلومات مهمة منهم:
انه مدام في سيرفر ف انا بعرف انا رح استخدم ال pymysql لانه من اسمها microsoft server ف في سيرفر بالموضوع
في اسم لل user، وفي باسوورد برضه، وفي اسم لل database الذي بدي اطول منها
هدول كلهم variables من نوع string انه انا بجهاز المعلومات عشان هلاً استخدمهم كمان شوي
- سطر 23 انا هون زي كآني بحكيه امسكلي هاد المكان واعمللي معه connect واستخدمت ال pymysql.connect عشان اعمل هاد الاشي
وبتلاحظوا انه في parameters للمعلومات الاساسية زي ال server, user, password والخ، ف انا بمسك ال variables الذي انا عملتهم فوق وبعبني هاي المعلومات من خلالهم
- سطر 25 اخر اشي خالص بدي اطول البيانات وانفذ ال query الذي كتبتها فوق واحطها ب dataframe عن طريق pandas وبستخدم pd.read_sql وبكتب اول اشي ال query والذي هي البيانات الذي بدي اطولها، بعدين بحط اسم ال object الذي انا عملته الذي وظيفته انه يطوللي ويمسكلي مكان هاي ال database وخزنتها ب variable اسمه studentmath
- اخر اشي سطر 26 عملت close لل object انه خالص سكرلي المكان الذي انت عملت معه connect لاني طللت البيانات الذي بدي اياها وخلصت
- سطر 30 ل 33 نفس الاشي بس الفرق انه انا عندي متغير host ف من خلاله بعرف انه عندي host ممكن يكون local يعني الداتا على جهازك بال mysql او من برا، ليهك انا بعرف انه رح استخدم mysql باكيج، لانه انا ما عندي سيرفر هون، عندي هوست
- باقي الخطوات نفس الاشي وبنعرف شو بتعمل

Handling Missing Values:

- ال missing value هي انه جزء من البيانات مفقود عندي بال data set اللي عندي
- كيف بعرف انه هاي missing value؟ يكون مكتوب NaN
- كيف اقدر اعرف كم missing value عندي؟
من خلال df.isnull()، هلا هاي رح ترجعلي نفس ال shape تاع ال data frame اللي عندي وال values اللي فيها عبارة عن True, False، بتكون True لما يكون فعلا هاي القيمة هي عبارة عن null value، وبتكون False لما ما تكون null value
- بس اذا حجم البيانات كبير يكون صعب عليك انك تشوف كل قيمة اذا هي True, False، لهيك احسن اشي تعمله df.isnull().sum() انت هيك جمعت ال null values وشفت لكل column كم من null value عندي
- طبعا اذا بدك تشوف كم null value ل column معين بتقدر من خلال df['column name'].isnull().sum()
- انت لما يكون عندك null values لازم تتعامل معهم اما عن طريق ال drop او ال fill
ال drop طريقة risky لانه انت رح تخسر بيانات، بنفذاها من خلال df.dropna()
احسن اشي هي طريقة ال fill واللي هي بتعبي مكان ال null values القيمة اللي انا بعتيها اياها، ممكن اعبي بال mean او ال median او ال mode الخ من هاي الاشياء، بنفذاها من خلال df.fillna(value)
- الفيديو [اللي هون](#) عبارة عن شرح عملي لهاد الموضوع
- هاي الاكواد تلخيص لاهم ال methods وهاي الاشياء يعني و هي ال [notebook كامل هون](#)

```
1 import pandas as pd
2 df = pd.read_csv('item.csv')
3 df.head()
4 df.isnull()
5 df.isnull().sum()
6 df.dropna()
7 mean = df['afternoon'].mean()
8 df['afternoon'].fillna(mean, inplace=True)
```

- معلومة بسيطة اخر اشي ، هلا في طريقة لتعباية ال null values اسمها interpolate، هلا هاد المسمى العام لها، بس هي عبارة عن شو؟ بدنا نعرف انه الها طريقتين الاولى هي forward والتانية هي backward
- هلا الفكرة مثلا بال forward انه اذا انا عندي null value بنص العمود فهو شو بعمل؟ هو بمشي من اول العمود لحد ال null value وبحاول بيني relation ، وبعبي هاي ال null value بهاي القيمة اللي طلعت معه ، ومهم جدا نعرف شغلة انه

ال forward ببليش من اول العمود، لهيك اذا كان عندي اول العمود null value ف هاي الالية مش راح تزيط معنا ورح اول قيمة تضلها NaN لانه ما لحق بيني علاقة عشان يعبيها

هلا ال backward نفس الاشئ بس بالعكس، يعني ببليش من اخر العمود وببليش يطلع لفوق، لهيك اذا كانت اخر قيمة بالعمود عندي عبارة عن null value ف رح تضلها NaN لاني انا عامل backward

في ناس بتعمل forward اول اشئ بعدين backward عشان يضمنوا انهم يعبوا كل ال null values وما يضل ولا وحدة عندي بالداتا اللي عندي

```
1 import pandas as pd
2 import numpy as np
3
4 dict = {"First Score": [100,90,np.nan,95],
5         "Second Score": [30,45,56,np.nan],
6         "Third Score": [np.nan, 40,80,98]}
7
8 df = pd.DataFrame(dict)
9
10 print(df.isnull().sum())
11
12 print(df.interpolate(method='linear', limit_direction='forward'))
```

- هلا جوا ال interpolate function بدنا نخط ال method وهون احنا حطيناها linear، ممكن تحط polynomial والخ من هاي الاشياء
- بعدين حطينا ال limit_direction واللي هي forward وهون انت ممكن تغيرها وتحطها backward
- ملاحظة: انا اللي عملت هاي ال dataframe مش طلقتها من ملف او اشئ، ثاني اشئ ال np.nan هي بتعمللي null value جوا ال data وعملنا هيك بس عشان نفرجكم كيف انه آلية تعباية ال null values من خلال ال interpolate function

Data Cleansing:

مصطلح ال data cleansing هو اشملى و اعم من ال data cleaning وممكننا ناس تحكي عنه data wrangling

What is Data cleansing?

Data cleansing is the process of removing or resolving poor-quality data records from the source, which can vary based on the technology used to persist the data, such as a database table or encoded file.

Poor-quality data can be identified as any data that does not match the producers' intended and defined requirements. This can include the following:

- **Missing or null (NaN)** values from the fields of one or more rows
- **Orphan records:** primary or foreign keys cannot be found in any referenced source tables
- **Corrupted records:** cannot be read by any reporting or analysis technology

It is always recommended to clean data as close to the source as possible. This will save time by avoiding any human/system errors in the data processing pipeline.

Missing or null (NaN):

- حكيما عنهم بالجزئية اللي فوق

Orphans Columns:

- ال orphans columns باختصار همة ال columns اللي بتكون ال value تاعته unique لكل column ، زي ال ID ، انه كل شخص اله ID مختلف عن التانية لهيك هاد يعتبر orphan column
- طيب انا شو اعمل بهاد ال column؟ بعمله drop من ال داتاسيت اللي عندي قبل عملية ال modeling ليش؟ لسببين:

الاول هو انه اذا انا خليت هاد ال column ودخلته بال machine learning model ف هو رح يفكر او رح يوخد ال ID هو الاشى الاساسي اللي بخليني انتبأ بال target اللي عندي، ولو عملت training للموديل وبعدين عملت testing ع نفس البيانات اللي عملتها training ف ال accuracy رح تطلع 100%، ليش؟ لانه هاي العملية واحد ل واحد وبصير زي كاني غششته انه اللي ال ID تاعه كذا ، ف خلص دايركت ال target كذا كذا

بس، الو علمت predict لل testing data فال accuracy رح تطلع اقل بكثير لانه ال ID's اللي حيشوفها هي جديدة تماما وما عمره شافها، لهيك ما رح يعطي results كويسة

السبب التاني، انه انا بخليهم وبشيلهم قبل ال modeling ليش؟ لانه انا اذا بدى اعمل merge مع داتاسيت تانية، ف انا بعمل merge عن طريق ال ID column لهيك لو انا شلته عالسريع ومن اول ما بلشت شغل، ما رح اقدر اعمل merging مع اي داتا تانية، لانه ال primary key انا حذفته

وفي ناس دايمما بتعمل copy من الداتا قبل ما تحذف هاد العمود ، عشان تخلي منه copy بقدر ارجعلها متى مبيدي

Corrupted Records:

- هو باختصار ال records اللي بكونوا خربانين، يعني مش قادرين نقرأهم وفيهم corrupted data والمفروض اني اشيهم

Binning Data:

Binning data

Binning is a very common analysis technique that allows you to group numeric data values based on one or more criteria. These groups become named categories; they are ordinal in nature and can have equal widths between the ranges or customized requirements.

A good example is age ranges, which you commonly see on surveys:

- Q: What is your age?
- Under 18 years old
 - 18 – 24
 - 25– 44
 - 45 – 74
 - 75 years or older

Another common example is weather data, where the assigned categories of hot, warm, or cold are assigned to ranges of Celsius temperature. Each bin value is defined by a condition that is arbitrarily decided by the data engineer.


- ال binning data هو اني انا اقسم column تكون ال values تاعته عبارة عن continues values، على سبيل المثال (زي المثال اللي بالصورة) عندي عمود عبارة عن ال ages ال values تاعونه حتكون عبارة عن: 16,21,33.5,62 الخ ف اللي بعمله هو اني اقسم البيانات ل bins، ايش يعني bins؟ يعني اني انا اخلي ال values بدل ما تكون ارقام، اخليها ranges، كيف يعني ranges؟ اني انا اخلي ال اعمار بدل ما تكون 18,19,20,21,22,23,24 تكون بس عبارة عن ال value ال range اللي هو 18-24، هاد على سبيل المثال، انت بتحدد ال range اللي بدك اياه

Combining, Merge, and Join Data:


- مرات يحتاج اني ادمج 2 tables مع بعض، والدمج بصير عن طريق ال primary key او ال orphan column اللي حكينا عنه، هالأ عنا قوانين او قواعد او طرق لل merging

Merging/Joining DataFrames

- Merging dataframes deals with how to line them up by row.
- When referring to databases, merging is traditionally called a join.
- There are four types of joins: **full (outer)**, **left**, **right**, and **inner**.
- The result will be affected by values that are only present on one side of the join.
- Joins Venn diagrams help us visually understand the differences.



- شرح فيديو عن الموضوع [من هون](#)
- الكود او ال notebook [من هون](#)



- المفروض انه احنا بنعرف كل طريقة عن الثانية ب ايش بنفرق، بس للاحتياط، رح اشرحهم بالفيديو اللي رح احط اللينك تاعه بعد شوي

- في صورة لطيفة بتشرح هاد الموضوع واللي هي اللي عالشمال:
- ب pandas في عندي 2 functions ل شغلة ال joins:

pd.concat() واللي هي بتعمللي بس ال inner وال outer

والثانية pd.merge() واللي هي بتعملي كل انواع ال joins لهيك احنا ممكن نعتبرها انها اعم من ال pd.concat()

- شرح فيديو عن الموضوع [من هون](#)
- الكود او ال notebook والداتا وكلشي [من هون](#)

Data Visualization:

- فيديو شرح عن الموضوع [من هون](#)
- الكود او ال notebook والداتا وكلشي [من هون](#)


Detect Outliers Through Visualization:

- فيديو شرح عن الموضوع [من هون](#)
- الكود او ال notebook [من هون](#)

Feature Engineering:

- اول اشي بدنا نعرف انه في فرق بين ال data engineering وال feature engineering
مثلا ال data engineering هو اني اعمل cleaning لل بيانات و handling missing values وهاي الاشياء، يعني انه يشتغل عالداتا نفسها
اما ال feature engineering هو اني اشتغل عال features اللي عندي واللي همة ال columns عن طريق اما اعمل extracting features from one features, merging و الخ من هاي الاشياء، بس انه الفكرة العامة انه انا يشتغل عالفيترز نفسهم عشان اجهزهم لل machine learning
- ثاني اشي بدنا نحكيه انه عملية ال feature engineering بتصير قبل عملية ال modelling وبعد عملية ال data engineering للبيانات، يعني ال workflow للبيانات صار عنا اول اشي نجيب البيانات ونجمعها ، بعدين نعمل cleansing للبيانات اللي عنا و data engineering بشكل كامل، بعدين بنعمل feature engineering ، بعدين بنبلش عملية building the model ، والصورة اللي تحت رح توضح هاد الاشئي.

Typical Enterprise Machine Learning Workflow



- زي ما حكينا قبل انه مهم نميز اذا الاشياء اللي احنا بنعمله هو data engineering وال feature engineering لهيك الصورة اللي تحت رح توضحلنا اشياء لا تعتبر جزء من ال feature engineering

That's NOT Feature Engineering


- Initial data collection
- Creating the target variable.
- Removing duplicates, handling missing values, or fixing mislabeled classes, it's data cleaning.
- Scaling or normalization
- Feature selection, although I'm going to mention it in this talk 😊

- هلا تجميع البيانات و احدد ال target واشيل ال duplicate او اعمل normalization وكل هاي الاشياء لا تعتبر feature engineering ليش؟ لانه انا ما غيرت اشي عال features ال features لسا زي ما همة، وما ضفت وعملت extract ل features من feature معين، ولا عملت integration ل feature من مجموعة features ولساتهم يعني ال features نفسهم ما تغير عليهم، لهيك هاي الاشياء لا تعتبر feature engineering

- هلا في شغلة ال feature selection ايش معناها؟ انه مثلا انا عندي 5 الاف feature بالداتا تاعتي، بزبطش احطهم كلهم بال machine learning model لانه عددهم هائل، ف انا بحدد مثلا انه رح اختار منهم 50، بس بناءا على ايش بختارهم؟ بختارهم بالنسبة للاهم لل model او ال target اللي عندي، وهلا هاد موضوع كبير شوي ورح نحكي عنه لقدام وبالمواد الجاي، بس حلو انكم تفهموا شو هو، وال model selection لا يعتبر جزء من ال feature engineering لانه زي ما حكينا ال features زي ما همة، احنا بس عملنا select ل جزء منهم

- هلا ال cycle تاعة ال feature engineering صارت كالاتي، وخلينا نشرح اول اشي عن ال hypothesis set الفكرة هون انه بده يكون خبرة بال domain او المجال تاع البيانات اللي عنا، عشان نعرف ايش اهم ال features ونعرف نشتغل عليهم وهكذا ، وانه يكون عنا خبرة سابقة بهاد الموضوع، ونعرف نشتغل على عملية ال EDA اللي هي Exploratory Data Analysis ، واخر اشي انه نوخذ feedback من الموديل تاعنا، انه كيف ال accuracy؟ كويس ولا مش كويس، واذا لا ارجع اعدل عال features وارجع اشتغل عليهم واشوف اذا الموديل حيصر احسن او لا، لحد ما الاقي احسن طريقة لل model تاعي.


Feature Engineering cycle



H₂Oai

- هلا رح نحكي عن ال validate hypothesis زي اني اعرف كيف اعمل validate لل موديل تاعي، و هل انه اعمل cross-validation للبيانات اللي عندي، اعرف نوع ال metrics اللي رح استخدمهم ل اعمل evaluate لل موديل تاعي، واخر اشي اني اتجنب ال leakage اللي هو التسريب، يعني بما معناه انه يكون عندي feature زي بتغشش الموديل بال target، ف هاد زي كانه بسرب معلومات لل موديل بخصوص ال training بس ممكن هاد ال feature ما يكون موجود لل testing لهيك انا لازم اتعامل مع هاد الاشئ. (لو ما فهمت الاشئ اتس او ك، سكيب)

Feature Engineering cycle



How?

- Cross-validation
- Measurement of desired metrics
- Avoid leakage

- طيب، هلا ال feature engineering يعتبر صعب ولازم يكون عندك خبرة بال domain ونوع الداتا اللي بتشتغل عليها، ويرضه لازم تعمل الاف التجارب لتشوف الانسب الك وللموديل وللداتا اللي عندك، على سبيل المثال زي ما حكينا قبل انه لما يكون عنا features كتير، ف لما بدي اختار عدد معين منهم ف ممكن انا اعمل تجارب وشاوف احسن مجموعة الي، لهيك هاي العملية بتاخذ وقت لانه بعمل تجارب كتير، والصورة التحت بتحكي عن الموضوع.

Why feature engineering is hard

- Powerful feature transformations (like target encoding) can introduce leakage when applied wrong
- Usually requires domain knowledge about how features interact with each other
- Time-consuming, need to run thousand of experiments

- احنا حكينا انه من ال feature engineering اني اعمل feature extraction او اعمل remove ل features ممكن تكون noisy، ف انا بهاي الحالة ببني موديل ابسط بنتائج افضل
- كمان اشي من ال feature engineering هو ال key element واللي بندرج تحته اكثر من موضوع، منها ال Target Transformation, Feature Encoding, Feature Extraction وهلا رح نشرح كل وحدة فيهم

Feature Engineering

- Extract more new gold features, remove irrelevant or noisy features
 - Simpler models with better results
- Key Elements
 - Target Transformation
 - Feature Encoding
 - Feature Extraction

- ال target transformation: وهو يعني انا اعمل عملية عال target column، وهي العمليات بعملها لما تكون عندي البيانات لل target عبارة عن skewed او يعني تركيزها او اغلب البيانات ب جهة معينة، او انها مش bell shaped ونا ممكن احل هاي المشكلة عن طريق اني اعمل transformations عال target column، ومن هاي العمليات اني اعمل ال $\log(x)$ لكل العمود او $\log(x+1)$ او $\sqrt{x}$ او $\sqrt{x+1}$ الخ من هاي العمليات


Target Transformation

- Predictor/Response Variable Transformation
 - Use it when variable shows a skewed distribution make the residuals more close to “normal distribution” (bell curve)
 - Can improve model fit
 - $\log(x)$, $\log(x+1)$, $\sqrt{x}$, $\sqrt{x+1}$, etc.

- والصورة اللي تحت مثال ل كيف شكل البيانات لما اعملها different kinds of transformation

Target Transformation

In Liberty Mutual Group: Property Inspection Prediction



Different transformations might lead to different results

- ثاني اشي اللي هو ال Feature Encoding: واللي هو باختصار اني احول ال categorical features ل numeric features، لانه اغلب خوارزميات ال machine learning ما بقبلو الا الارقام ك input

Feature Encoding

- Turn categorical features into numeric features to provide more fine-grained information
 - Help explicitly capture non-linear relationships and interactions between the values of features
 - Most of machine learning tools only accept numbers as their input
 - xgboost, gbm, glmnet, libsvm, liblinear, etc.

- في انواع لل feature encoding وهلا رح نتعرف على اكم من وحدة منهم زي ال label encoding وال one hot encoding

Feature Encoding

- Labeled Encoding
 - Interpret the categories as ordered integers (mostly wrong)
 - Python scikit-learn: LabelEncoder
 - Ok for tree-based methods
- One Hot Encoding
 - Transform categories into individual binary (0 or 1) features
 - Python scikit-learn: DictVectorizer, OneHotEncoder
 - Ok for K-means, Linear, NNs, etc.

- ال Label Encoding: هو اني يكون عندي feature مثلا يكون فيها 3 unique values، ف اللي بعمله هو انه بعمل لكل unique value رقم معين، وبالعاده بيلش من صفر، وبصير احط مكانها ب كل ال feature هاد الرقم، لهيك ال output لهاي العملية حيكون عمود واحد بس ال values بتختلف فيه، وهلا هاد الاشني او هاي العملية الها disadvantages ومنها انه انا لما اقسم ال unique values ل 0,1,2 ف انا بهاي الحالة ممكن يصير عندي bias و افضلية للبيانات على حساب بيانات ثانية، بس هاد الاشني ما بصير، لانه كل ال values المفروض متساويات بال importance، ف لما اقسمهم عن طريق ال label encoding ف انا هيكون عندي مخاطرة، و by the way ال label encoding هو نفسه ال ordinal encoding بس انه مسمى ال label encoding انه بنعمل encoding لل label او لل target feature

Feature Encoding

- Labeled Encoding

A	0
B	1
C	2

Feature 1	Encoded Feature 1
A	0
A	0
A	0
A	0
B	1
B	1
B	1
C	2
C	2

- هلا بهاد المثال عندي 3 unique values واللي هم A,B,C اعطينا ال A قيمة 0 وال B = 1 وال C = 2 على سبيل المثال، ف شوفوا كيف بال encoded feature صار عندي بس ارقام و عوض ال value بالرقم اللي اعطيناها اياه، طبعا ال values بتكون by default بتبلش من ال 0 بس ممكن انت تغير وتعطي كل value ايش الرقم اللي يطلع مقابله، واخر اشي بنلاحظ انه ال input عبارة عن 1 feature وال output برضه عبارة عن 1 feature

- و اخر شغلة بخصوص ال label encoding وليس انه ممكن يعمل bias او افضلية بالبيانات، لانه على سبيل المثال بال machine learning algorithm فيها عملية حسابية ، مثلا رقم 1000 ضرب ال value المقابلة لهاي ال feature، ف هاد الرقم للي هو 1000 ضرب 0 رح يعطيني صفر، و 1000 ضرب 1 رح يعطيني 1000 ، و 1000 ضرب 2 رح يعطيني 2000 ف شايفين الفرق بين ال values اللي طلعت من الموديل، كثير بنفرق واخر اشئ ، كله يرجع للاداتا اللي عندك، ممكن انت ك domain expert تحكي انه اه والله هاي الالية بتزبط للاداتا تاعتي، بس هاي لا، وهكذا.

- ال One Hot Encoding: هاي الالية بتعطيني new features بعدد ال unique values الموجودين ب feature معين او ال feature اللي بدي اعمله encoding، يعني مثلا عندي feature لل gender ال unique values اللي فيها عبارة عن male, female، ف رح يعمل 2 new features واحد لل male و واحد لل female واذا ال value اللي كانت بال feature الاصلي male ف رح يحط 1 عند ال feature_male و 0 عند ال feature_female، وهكذا لكل ال feature، ليهك ال input عبارة عن 1 feature وال output عبارة عن n features وال n هي عدد ال unique values اللي موجودين بال feature، وال One Hot Encoding هي نفسها عملية ال get dummies اللي احنا عملناها بالفيديوهات اللي قبل، ونفس الالية تاعتها ونفس كلشي، بس انه هاد المسمى تاعها ك encoding، والصورة اللي تحت مثال عالموضوع.

Feature Encoding

• One Hot Encoding

A	1	0	0
B	0	1	0
C	0	0	1

Feature	Feature = A	Feature = B	Feature = C
A	1	0	0
A	1	0	0
A	1	0	0
A	1	0	0
B	0	1	0
B	0	1	0
B	0	1	0
C	0	0	1
C	0	0	1

- وال disadvantage لهاي الالية انه اذا انا عدد unique values كثير، ف صعب اني اعملهم one hot encoding، لانه رح يطالع عندي عدد features هائل، ليهك لازم نعرف متى نطبق الالية هاي ومتى لا، وهل بتناسبنا او لا

Feature Encoding

• Frequency Encoding

- Encoding of categorical levels of feature to values between 0 and 1 based on their relative frequency

A	0.44 (4 out of 9)
B	0.33 (3 out of 9)
C	0.22 (2 out of 9)

Feature	Encoded Feature
A	0.44
A	0.44
A	0.44
A	0.44
B	0.33
B	0.33
B	0.33
C	0.22
C	0.22

- ال Frequency Encoding: واللي هو اني اعوض بدل كل value بمقدار معين، هاد المقدار هو قديه تكررت عندي هاي ال value بهاد ال feature، مثال بسيط عالسريع، عندي A,B,C وال A تكررت 50 مرة من اصل 100 وال B تكررت 30 مرة من اصل 100 وال C تكررت 20 مرة من اصل 100 هلا بعوض بدل ال A→0.5 وال B→0.3 وال C→0.2 ، بس هيك والصورة مثلا ل هالاشئ.

- ال Weight of Evidence: هي اني احوال ال continues feature ل discrete values feature، ب هالبساطة بس انه بدا ما يكون عندي 10.2,55,31,3.7 الخ، بقسمهم ل فترات او intervals انه من كذا ل كذا و هيك، وبعدين بس اخلص بطبق عليهم اي طريقة من طرق ال encoding اللي اخدناهم فوق

Feature Encoding – Weight of Evidence and Information Value

Information Value	Variable Predictiveness
Less than 0.02	Not useful for prediction
0.02 to 0.1	Weak predictive Power
0.1 to 0.3	Medium predictive Power
0.3 to 0.5	Strong predictive Power
>0.5	Suspicious Predictive Power

- السلايد اللي بالصورة اللي تحت مش مهم، بس للي بده يتطلع عليه يوخذ راحته


Feature Encoding – Numerical features

- Binning using quantiles (population of the same size in each bin) or histograms (bins of same size)
 - Replace with bin's mean or median
 - Treat bin id as a category level and use any categorical encoding schema
- Dimensionality reduction techniques – SVD and PCA
- Clustering and using cluster IDs or/and distances to cluster centers as new features

- في اشئ اسمه feature interaction و هاد الاشئ بصير لما يكون عندي features مرتبطين ب بعض بشكل كبير، او اني بقدر اطلع منهم feature او value منهم واستغني عنهم الجوز، على سبيل المثال، عندي feature للطول (نحكي مثلاً ل اراضي و هيك) و عندي feature ل عرض، ف انا ممكن اني احسب المساحة من خلالها واستغني عن ال 2 features، لانه ال 2 features مترابطين و بساعدوني اطلع معلومة جديد
- مثال ثاني، انا عندي بيانات فيها feature ل weight و feature ل height ف انا ممكن من خلالها اني اطلع ال BMI واللي هو ال body mass index من خلال ال formula تاعته واللي هي $bmi = weight / height^2$ ، وهي السلايد اللي بحكي عن هاد الاشئ، بس انت ممكن ما تفهمه، اذا فهمت الكلام اللي فوق ف هاد الاشئ كافي.

Feature Interaction

$$y = x_1^2 - x_2^2 + x_2 - 1$$



- تألت اشئ من ال feature engineering الئ ال feature extraction، على سبيل المثال ال location ممكن يكون فله معلومات كتير زي ال address, city, state, zip-code الخ، ف انا بعمل extract لهائ ال information كل وحدة ب feature لئال، ف هاد الاشئ اسمه feature extraction، هو اني اطلع ال features من ال features اوريدي موجودة عندي، والسلايد الئ تحت بعطي امثلة اكثر عن الموضوع.

Feature Extraction

- There usually have some meaningful features inside existing features, you need to extract them manually
- Some examples
 - Location
 - Address, city, state and zip code (categorical or numeric)
 - Time
 - Year, month, day, hour, minute, time ranges, (numeric)
 - Weekdays or weekend (binary)
 - Morning, noon, afternoon, evening, ... (categorical)
 - Numbers
 - Turn age numbers into ranges (ordinal or categorical)

- ال Feature Extraction بال Textual Data: هو اشئ اله دخل بال NLP ورح ناخذه بالتفصيل بمادة ال NLP بس بشكل عام الفكرة هي، انه انا عندي مجموعة documents وبدي اصنف كل document ل label اما يكون political يعني سياسي او sport يعني رياضي، كيف بعمل هاد الاشئ؟ عن طريق اني اخذ ال document واعمل dataframe، ال columns او ال features تاعونها عبارة عن ال unique words الئ بال documents، وال rows او ال instances عبارة عن ال document، اذا الكلمة موجودة بالملف المعين بحط 1 واذا تكررت كمان مرة بنفس الملف بزيد كمان 1 وهكذا، واذا ما مرت بالملف كله اصلا بحط القيمة 0، هيك انا بكون عملت dataframe لل bag-of-words، وهاد المصطلح الئ هو ال bag-of-words رح يتكرر كتير بمجال ال NLP، والسلايد الئ تحت بشرح اكثر عن الموضوع بس اذا فهمت الكلام الئ فوق ف هاد كافي.

Feature Extraction: Textual Data

- Bag-of-Words: extract tokens from text and use their occurrences (or TF/IDF weights) as features
- Require some NLP techniques to aggregate token counts more precisely
 - Split token into sub-tokens by delimiters or case changes
 - N-grams at word (often 2-5 grams) or character level
 - Stemming for English words
 - Remove stop words (not always necessary)
 - Convert all words to lower case
- Bag-of-Words Tools
 - Python: CountVectorizer, TfidfTransformer in scikit-learn package

Machine Learning with Iris Dataset:

- شرح فيديو للموضوع [من هون](#)
- الكود او ال notebook [من هون](#)

Sentiment Analysis:

- شرح فيديو للموضوع [من هون](#)
- الكود او ال notebook [من هون](#)

تم بحمد الله